深度第一次作業

目錄

實驗目的

實驗本資料集對於分類行為下，不同參數對普通Multilayer perceptron(MLP,多層感知器)所造成之影響，以及和eXtreme Gradient Boosting (XGboost)，在準確率，精確性，招回率以及F1-score 等評估指標的評價

資料集及分類目的

資料集

Predict students' dropout and academic

successhttps://www.kaggle.com/datasets/thedevastator/higher-education-predictors-of-student-retention/code

資料比數:4424是一份由34+1個欄位所構成

大致欄位有

狀況、申請方式、申請順序、課程、就讀時段（白天／夜間）、先前學歷、國籍、母親學歷、父親學歷等等

分類任務是依照Target分成3類分別是Graduate、Dropout、Enrolled(畢業、退學、在學)

各類別 筆數:比例

Graduate	2209:0.4993
Dropout	1421:0.3212
Enrolled	7940:1795

資訊獲利（Information Gain）

整體熵 = 1.4713

Curricular units 2nd sem (grade)	0.5150
Curricular units 2nd sem (approved)	0.4560
Curricular units 1st sem (grade)	0.4539
Curricular units 1st sem (approved)	0.3563
Curricular units 2nd sem (evaluations)	0.1391
Tuition fees up to date	0.1325
Curricular units 1st sem (evaluations)	0.1302
Course	0.0959
Age at enrollment	0.0895
Application mode	0.0753
Curricular units 2nd sem (enrolled)	0.0727
Curricular units 1st sem (enrolled)	0.0725

IG 值前5名平均值與Target關係

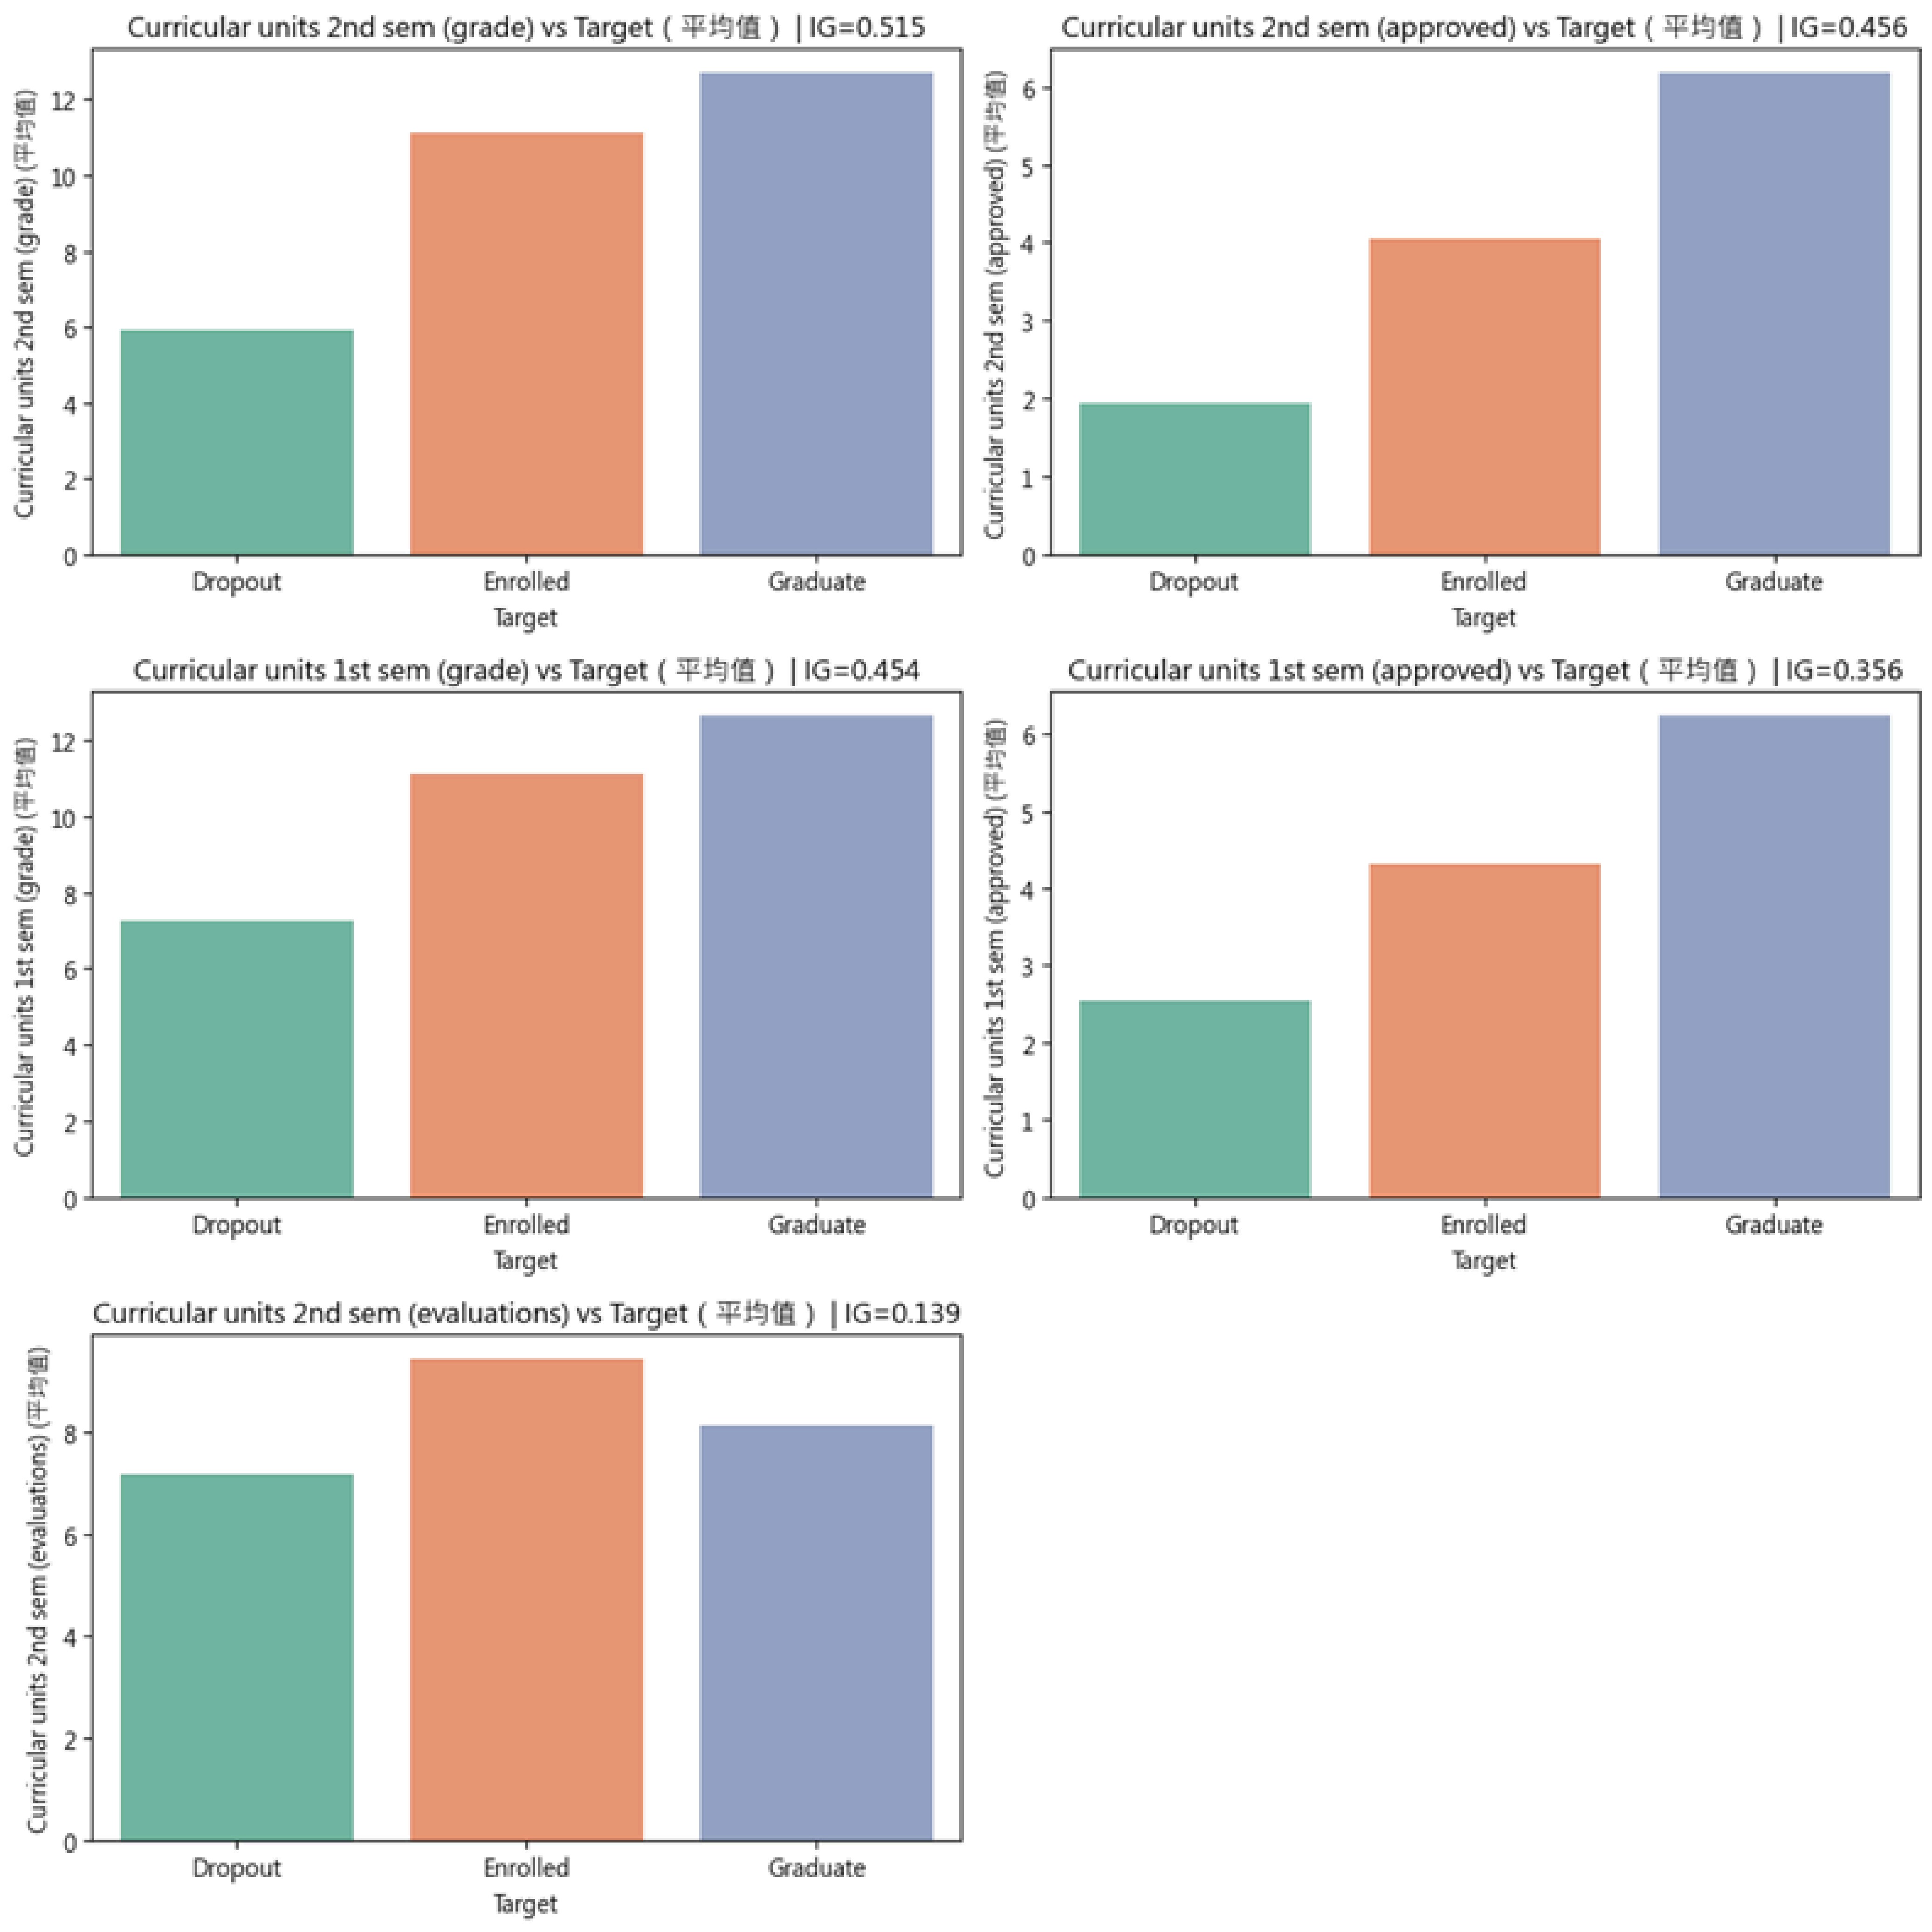

資料前處理方式

Targer設為目標欄位，並把Target 轉為類別

數值資料正規化(每個數值欄位變成均值 0、標準差 1)使用 StandardScaler()

對類別資料做One-Hot Encoding(熱編碼)

合併成單一特徵矩陣

對Target資料做LabelEncoding(0到k-1)

方法

對處理好的資料作資料切分，

- 訓練:驗證:測試->70:15:14
- 筆數為-> 3096:664:664

轉成numpy 在打包成PyTorch Dataset / Dataloader

建立loss函數

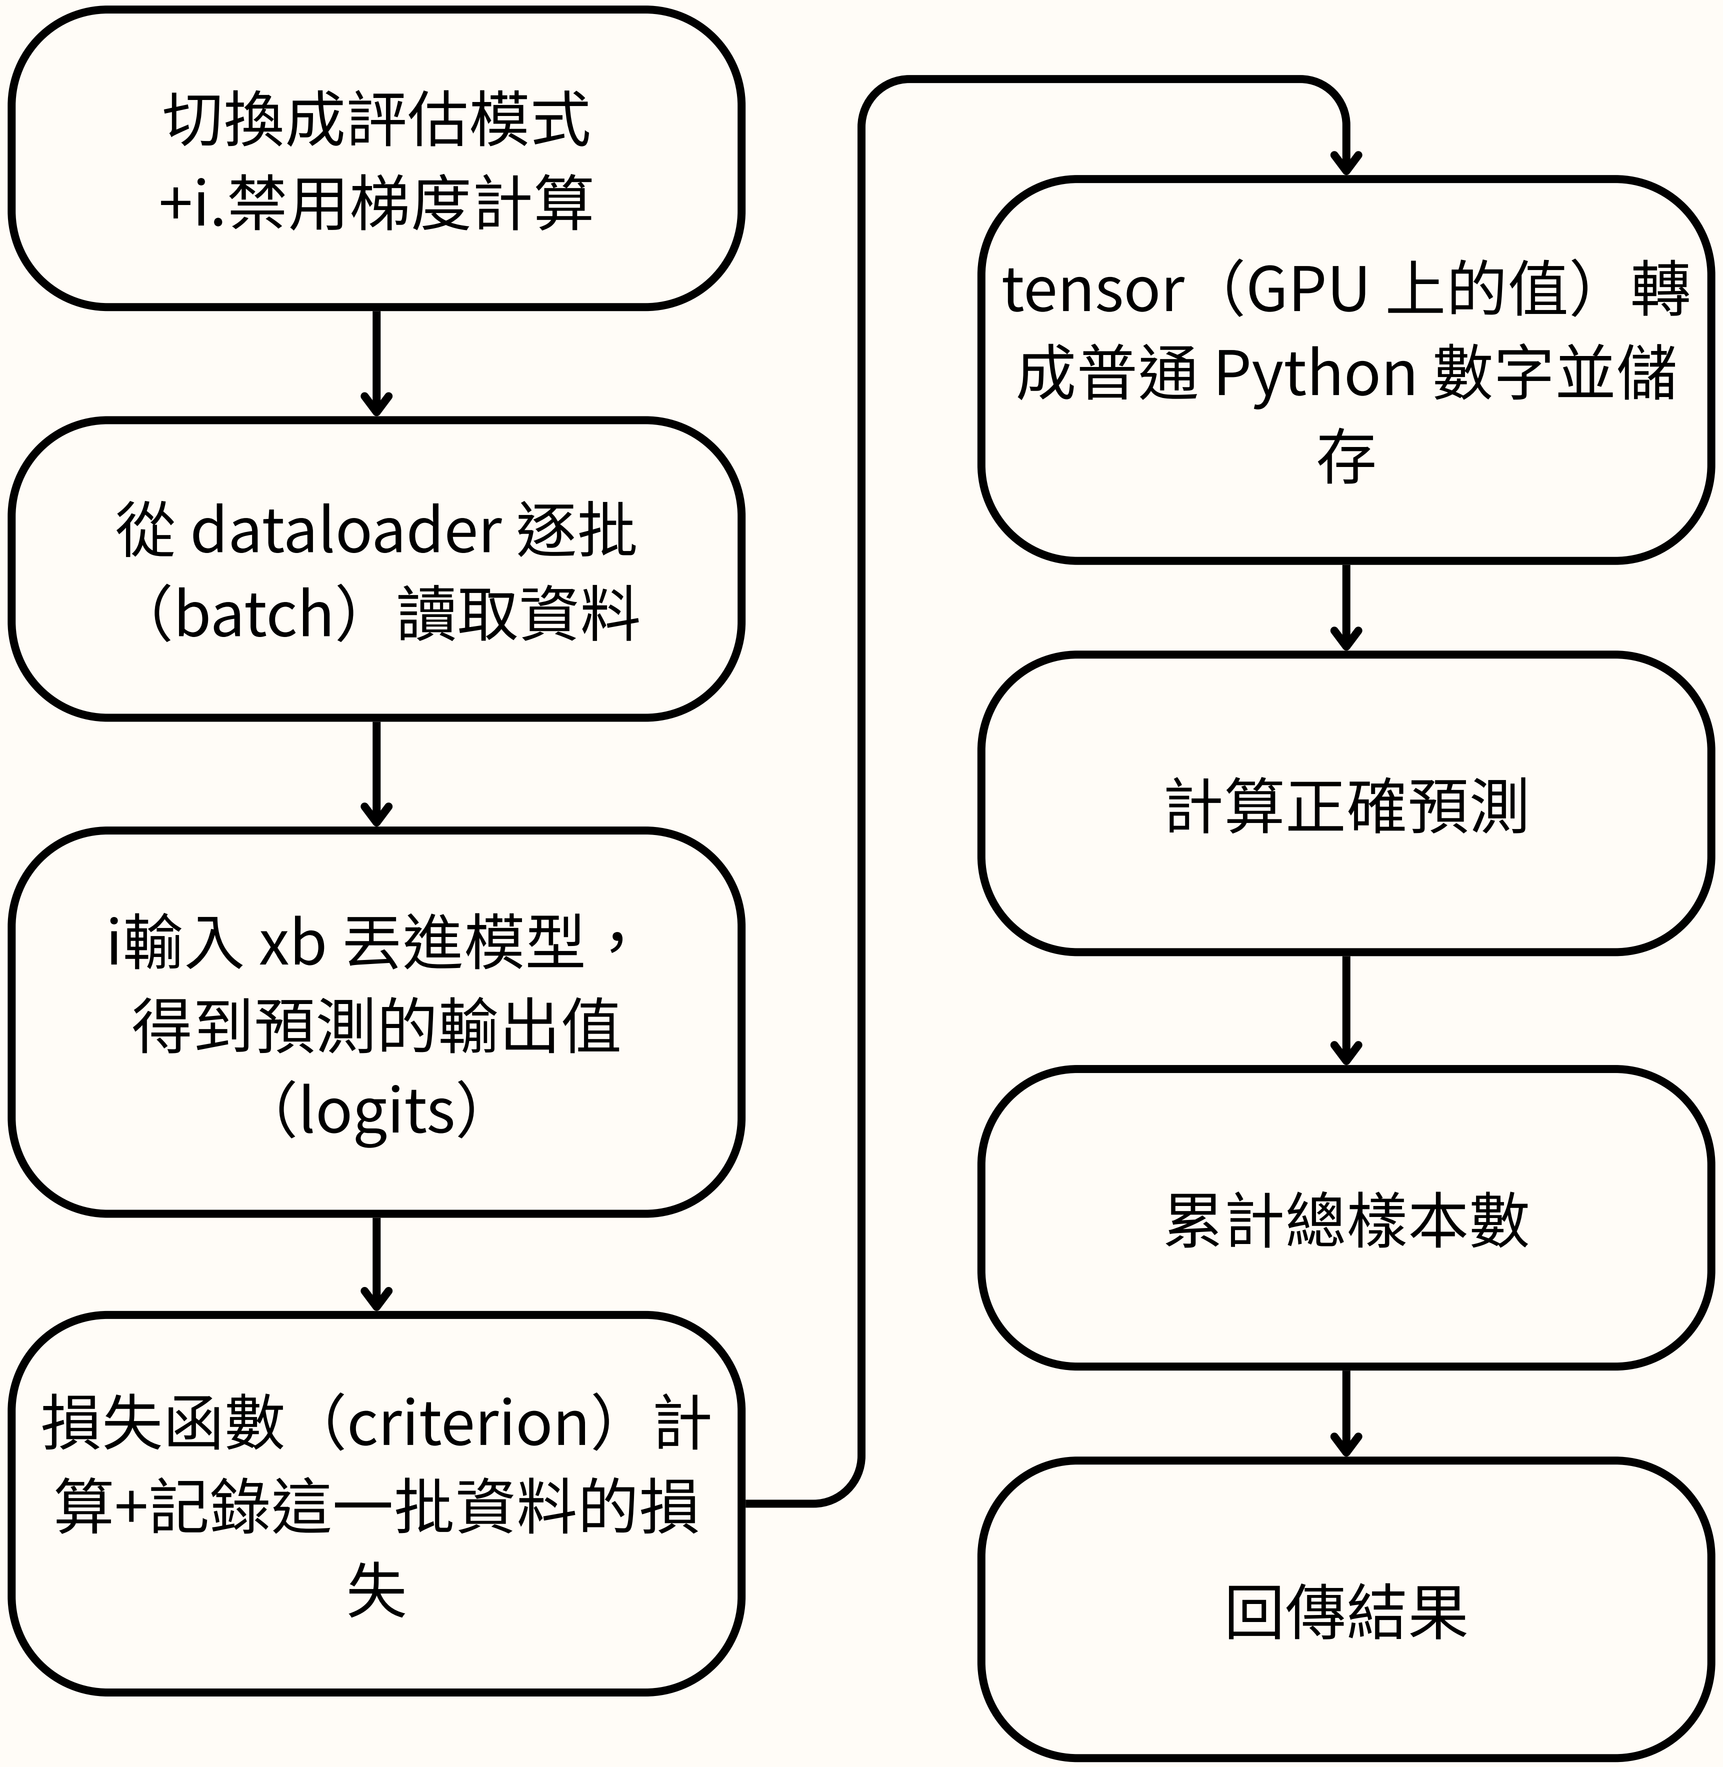
切換成評估模式
+i.禁用梯度計算
從 dataloader 逐批
（batch）讀取資料
i輸入 xb 丟進模型，
得到預測的輸出值
（logits）
損失函數（criterion）計
算+記錄這一批資料的損
失
tensor（GPU 上的值）轉
成普通 Python 數字並儲
存
計算正確預測
累計總樣本數
回傳結果

模
型
訓
練

固定多次訓練relu容易過擬和

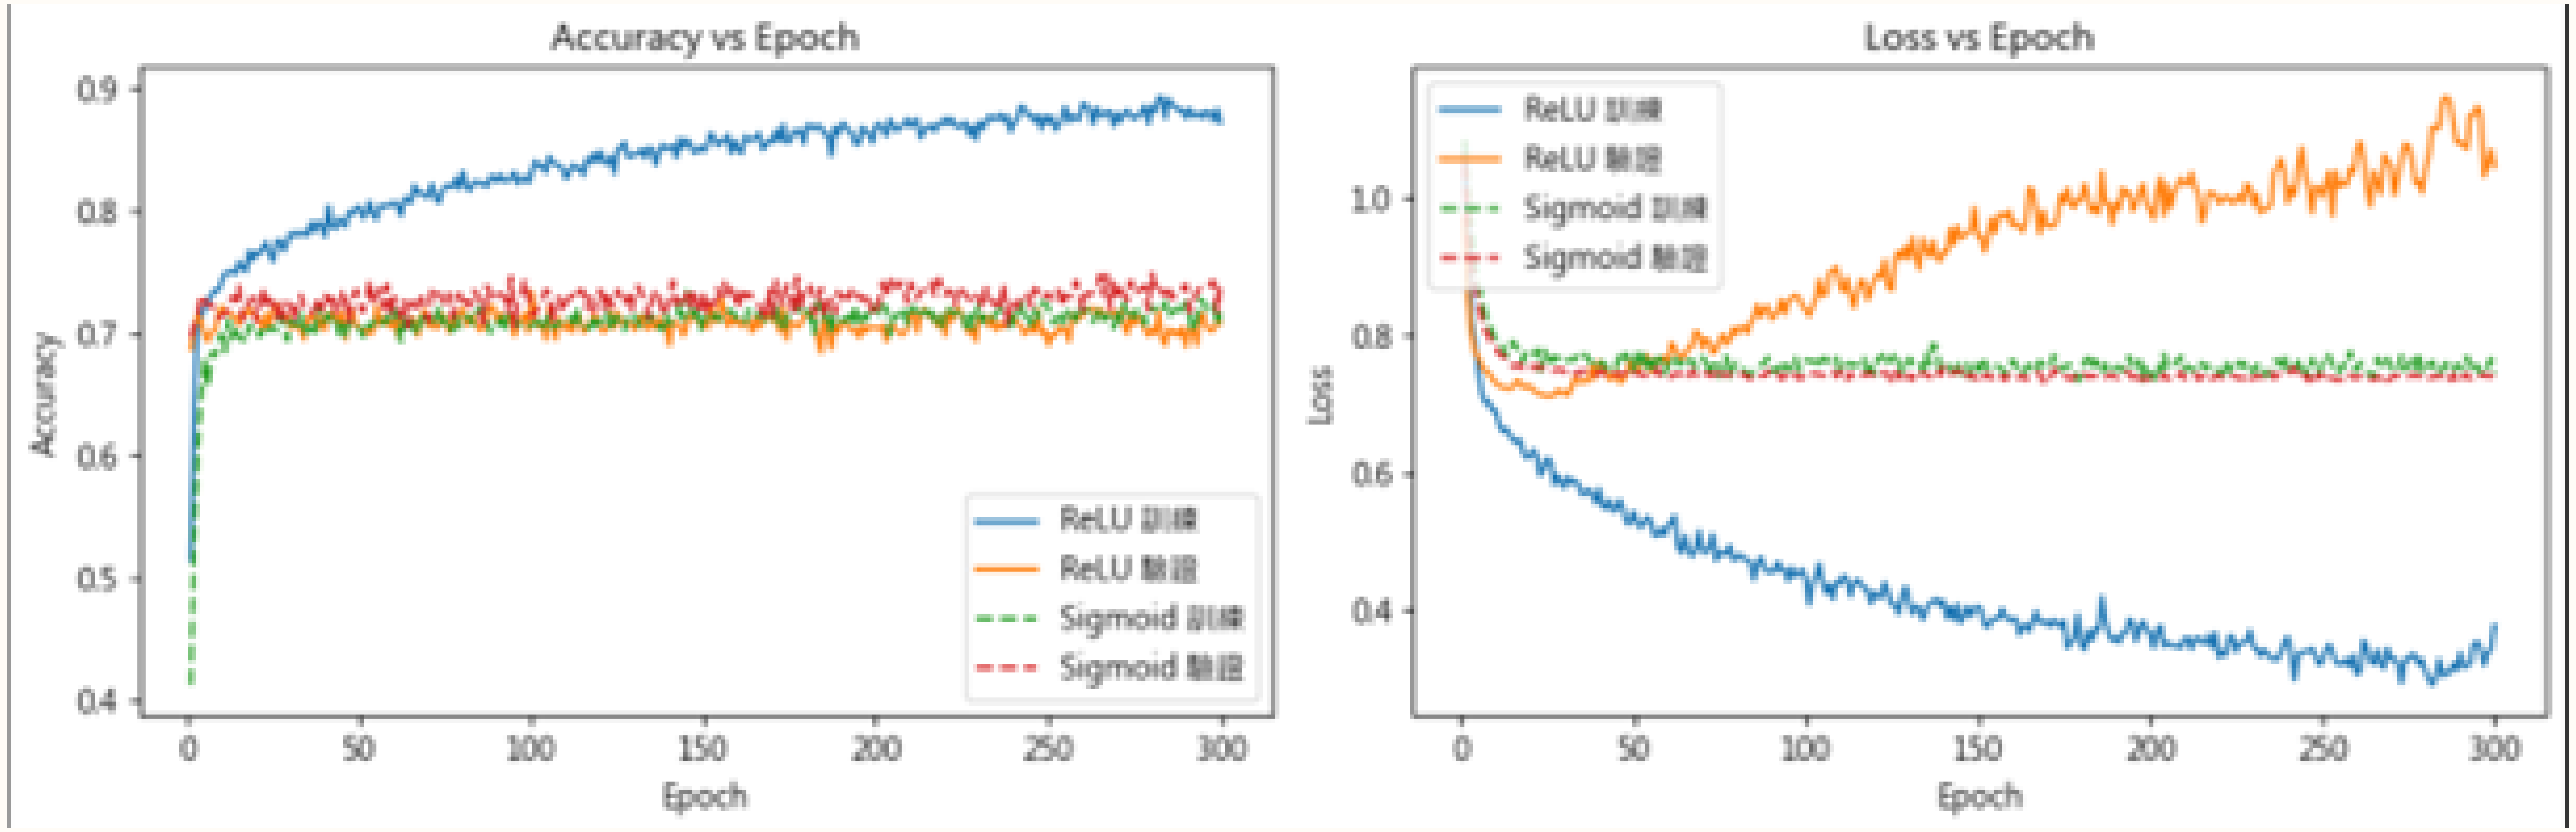

模型訓練

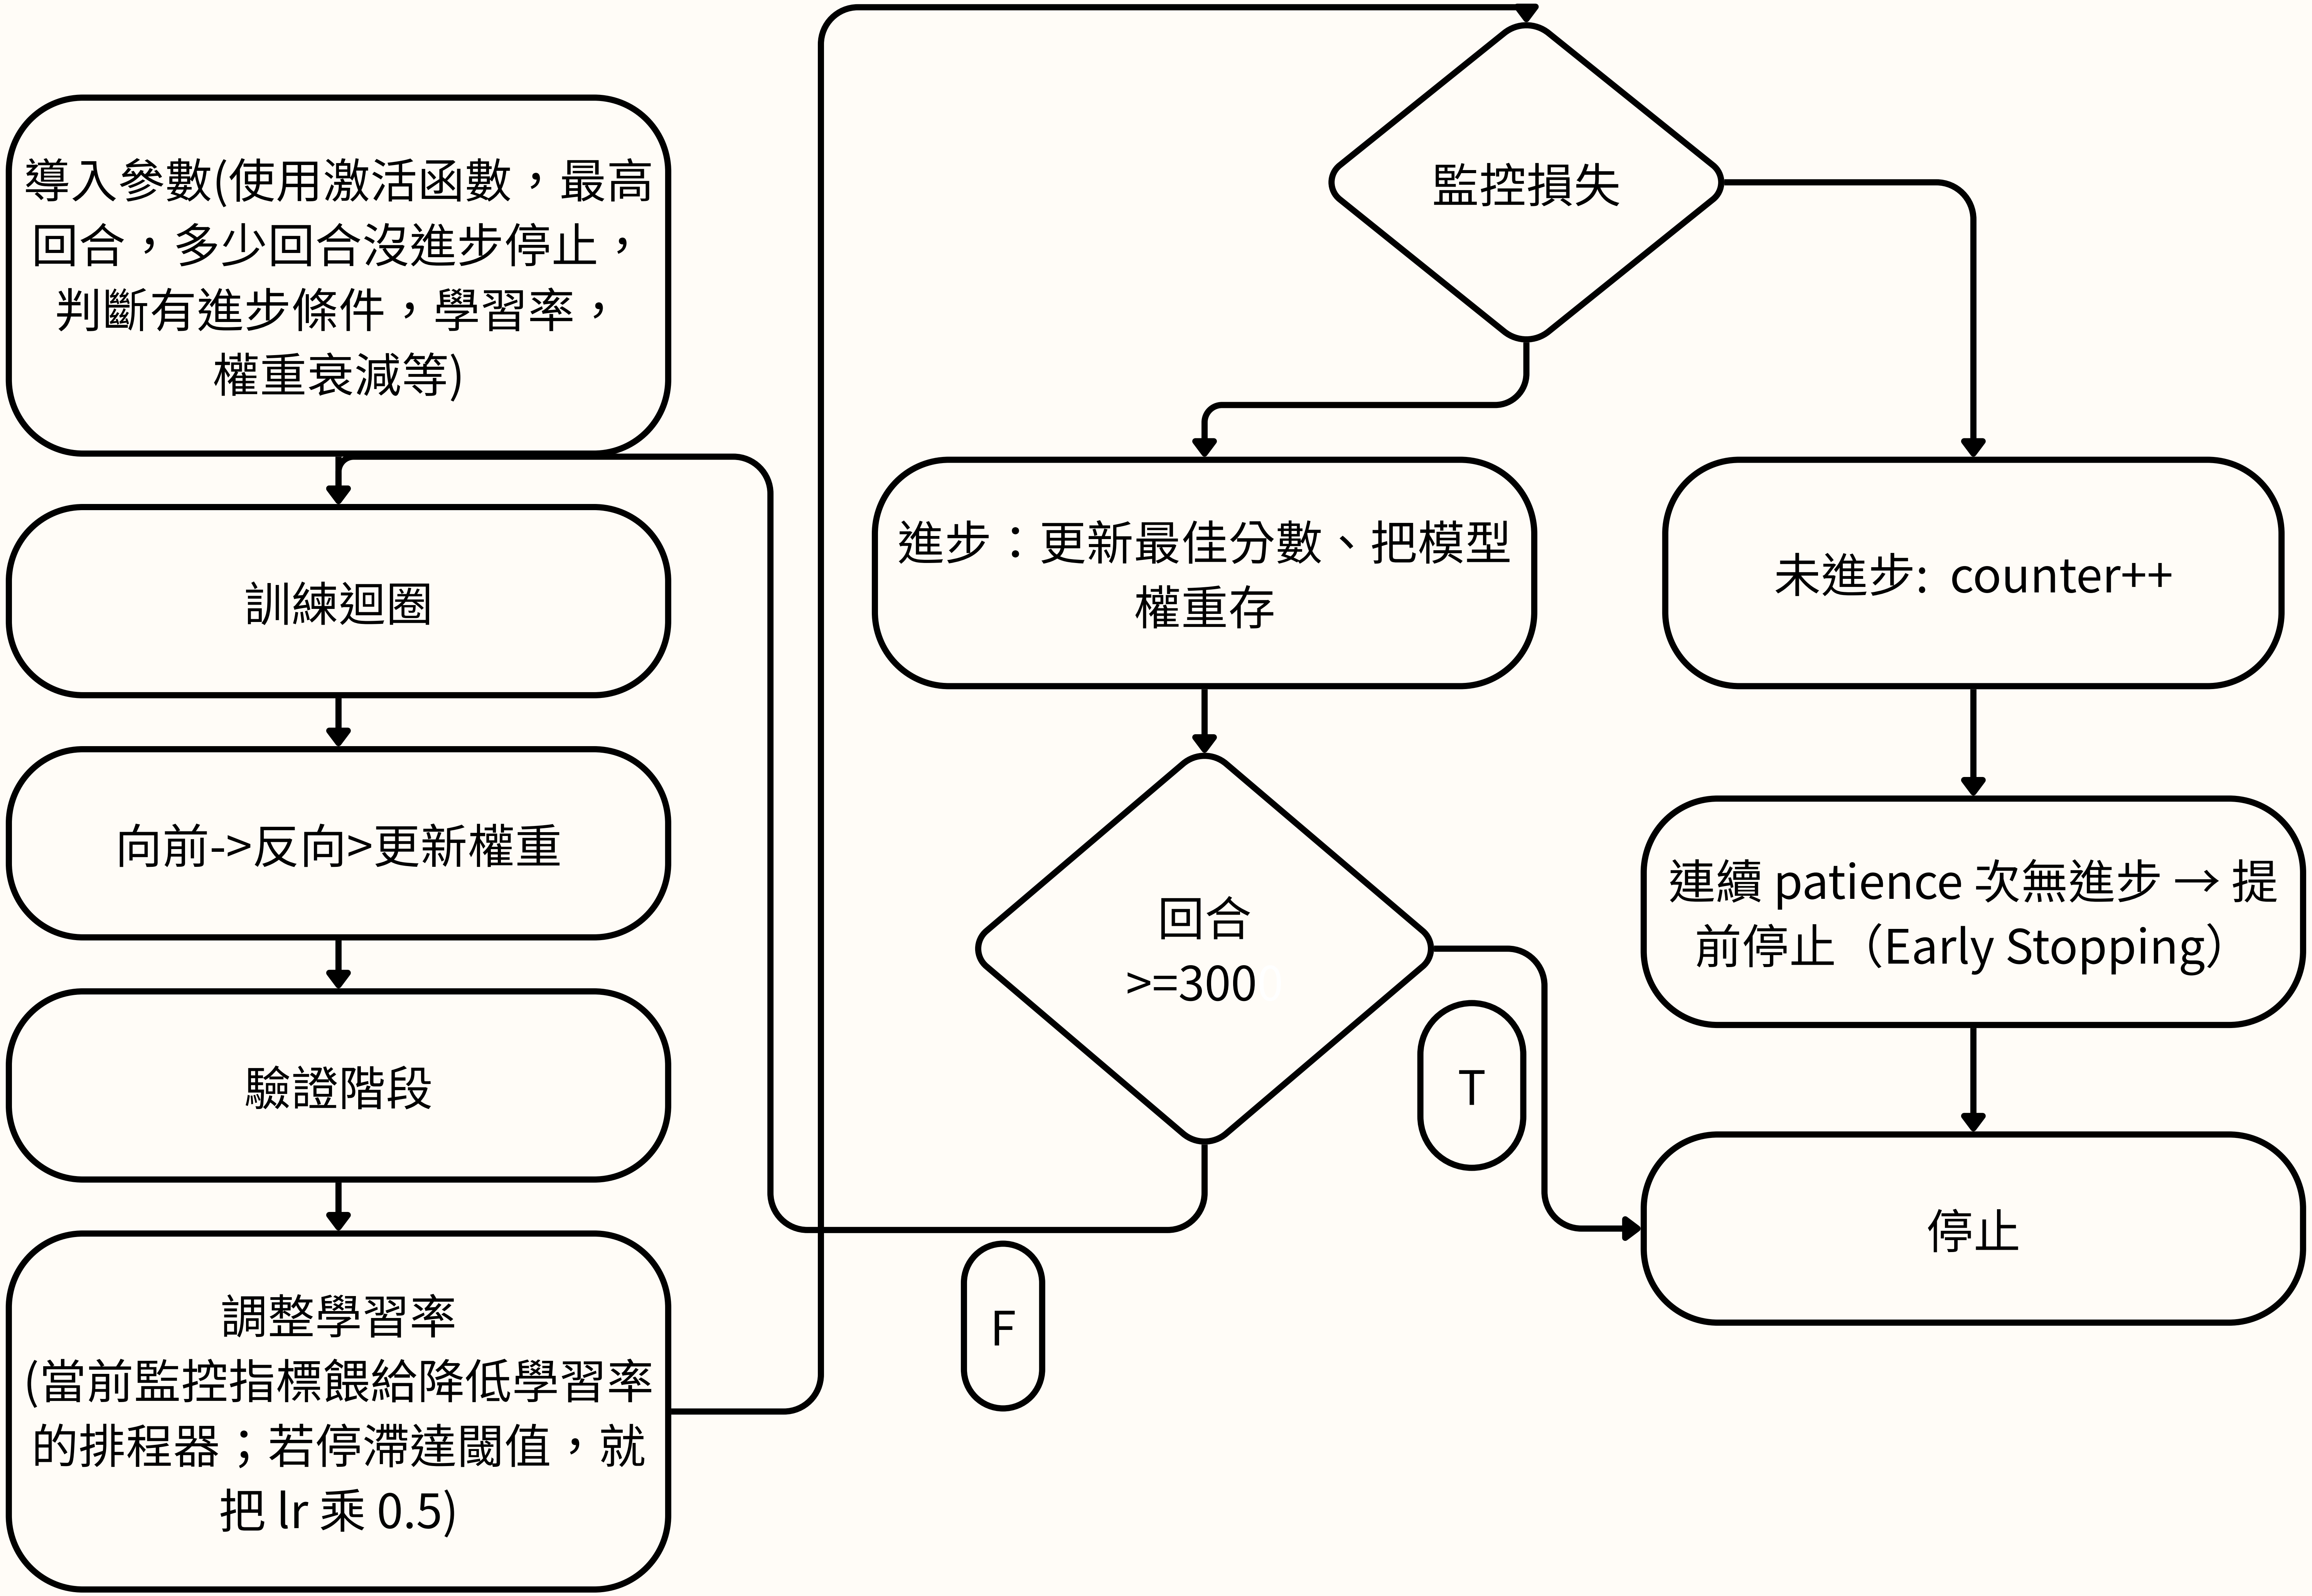
導入參數(使用激活函數，最高回合，多少回合沒進步停止，判斷有進步條件，學習率，權重衰減等)
訓練迴圈
向前->反向>更新權重
驗證階段
調整學習率
(當前監控指標餵給降低學習率的排程器；若停滯達閾值，就把 lr 乘 0.5)
監控損失
進步：更新最佳分數、把模型權重存
未進步：counter++
回合
>=300
T
F
連續 patience 次無進步 → 提前停止（Early Stopping）
停止

實驗設計

1. 隱藏層數(2、5)
2. 訓練 Batch size(256、1024)
3. 初始學習率(0.001、0.0003)
4. 激活函數(Relu 、 LeakyRelu(0.01))

以及另外訓練XGBoost作為比較

使用超參數

n_estimators=200, # 樹的數量
max_depth=6, # 每棵樹的最大深度 → 控制模型複雜度
learning_rate=0.05, # 學習率（eta）→ 每次樹貢獻的權重）
subsample=0.8, # 每次建樹時隨機抽取 80% 訓練樣本
colsample_bytree=0.8, # 每棵樹只使用 80% 的特徵（特徵隨機化）
random_state=42, # 固定隨機種子

結果

隱藏層數(2、5)

訓練

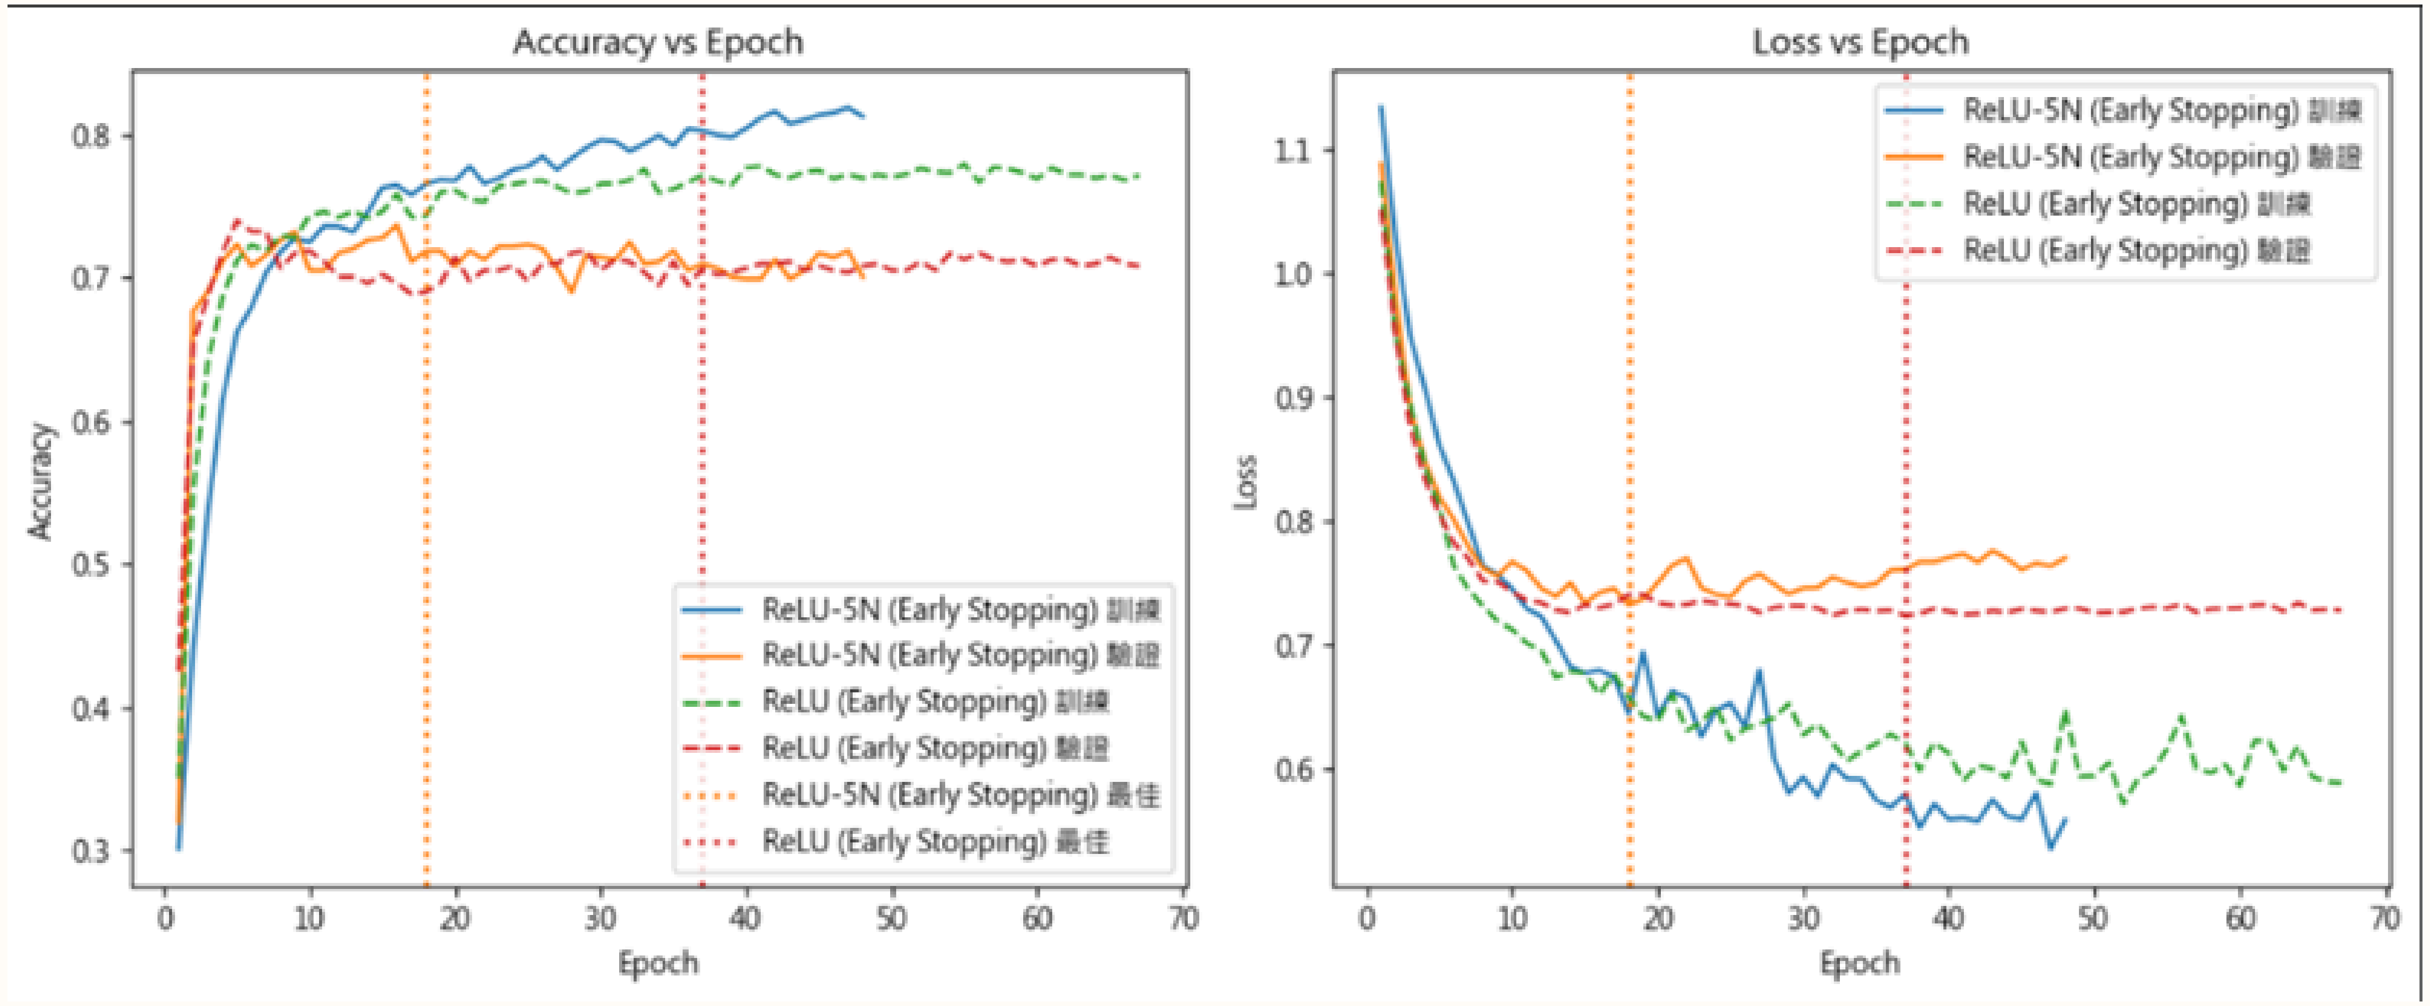


```
📊 === ReLU-5N (Early Stopping) 模型最終結果 ===
Train Loss: 0.5576
Val Loss:   0.7698
Train Acc:  0.8123
Val Acc:    0.7003

📊 === ReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.5878
Val Loss:   0.7275
Train Acc:  0.7713
Val Acc:    0.7078
```

測試

Accuracy 、Precision、 Recall 、 F1

2	MLP ReLU (ES)	0.748494	0.788433	0.748494	0.760966
3	MLP ReLU-5N (ES)	0.745482	0.797678	0.745482	0.761025

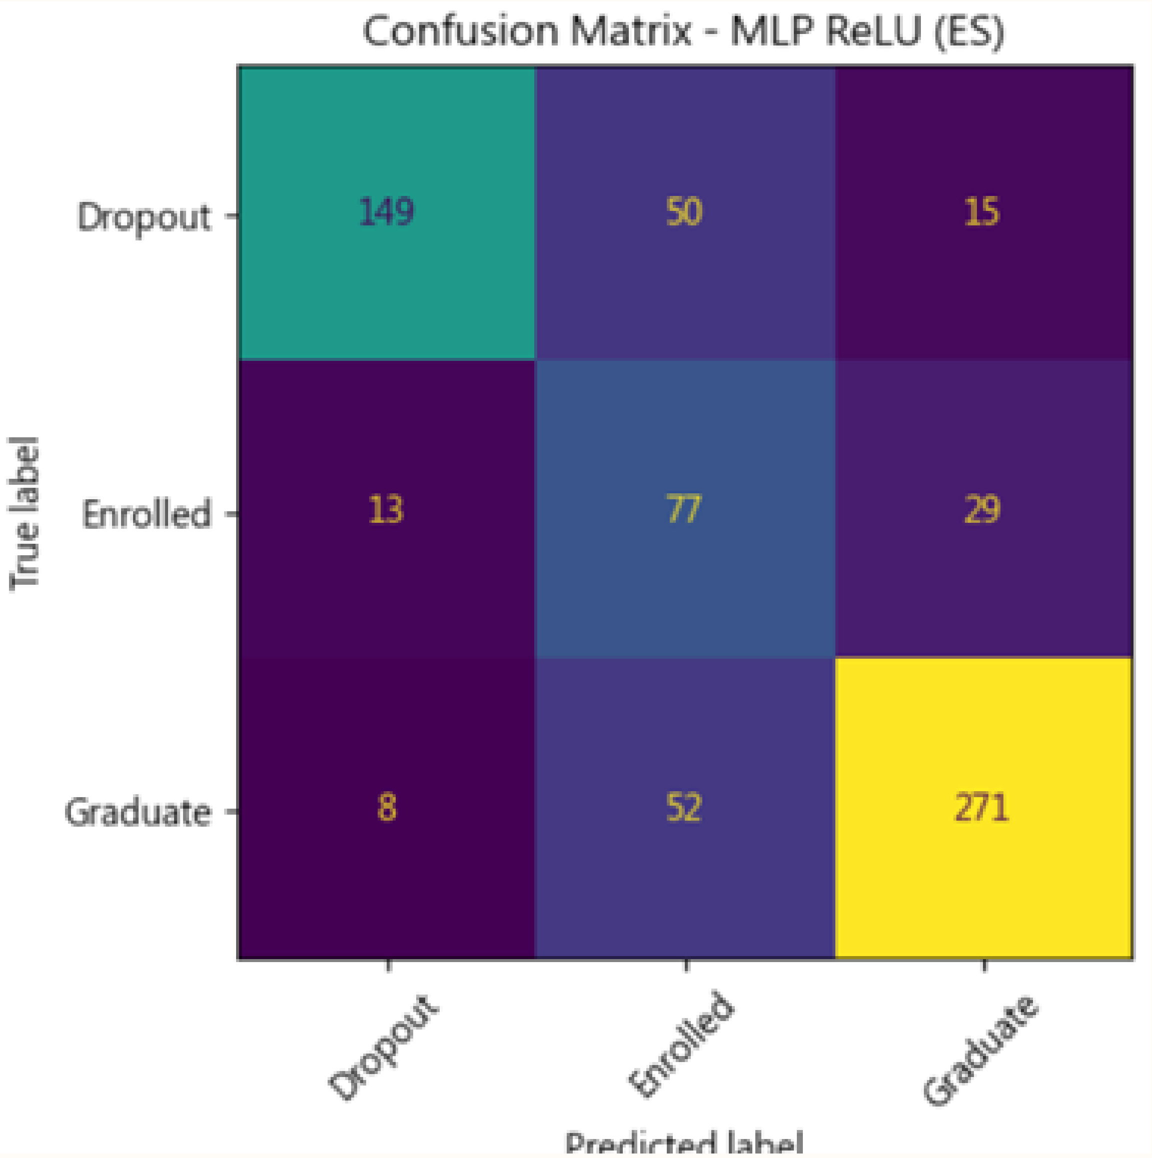

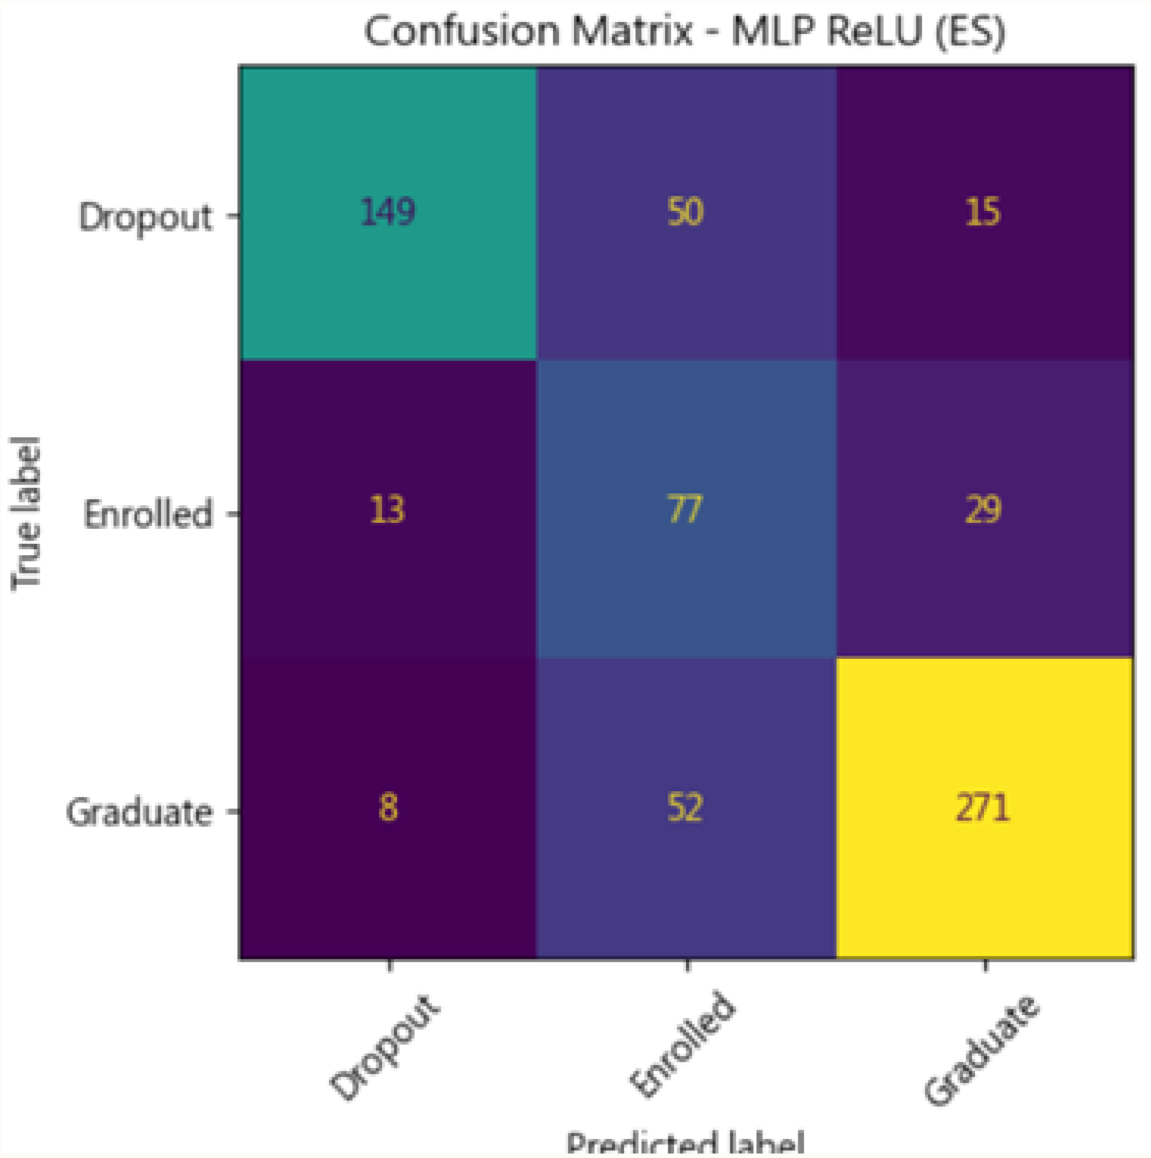

訓練 Batch size

訓練、驗證

Batch size=256

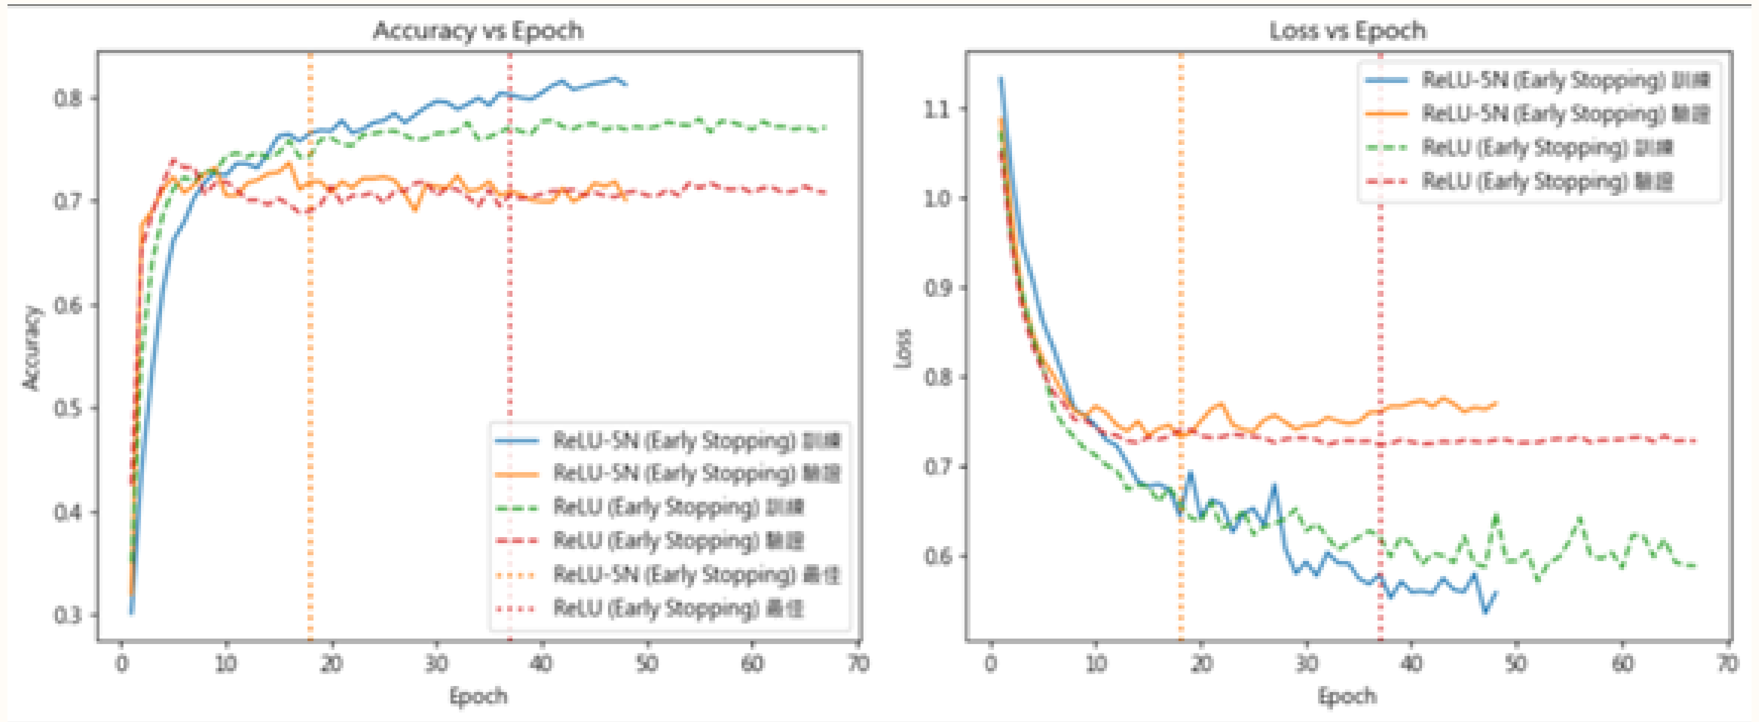


```
📊 === ReLU-5N (Early Stopping) 模型最終結果 ===
Train Loss: 0.5576
Val Loss:   0.7698
Train Acc:  0.8123
Val Acc:    0.7003

📊 === ReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.5878
Val Loss:   0.7275
Train Acc:  0.7713
Val Acc:    0.7078
```

Batch size=1024

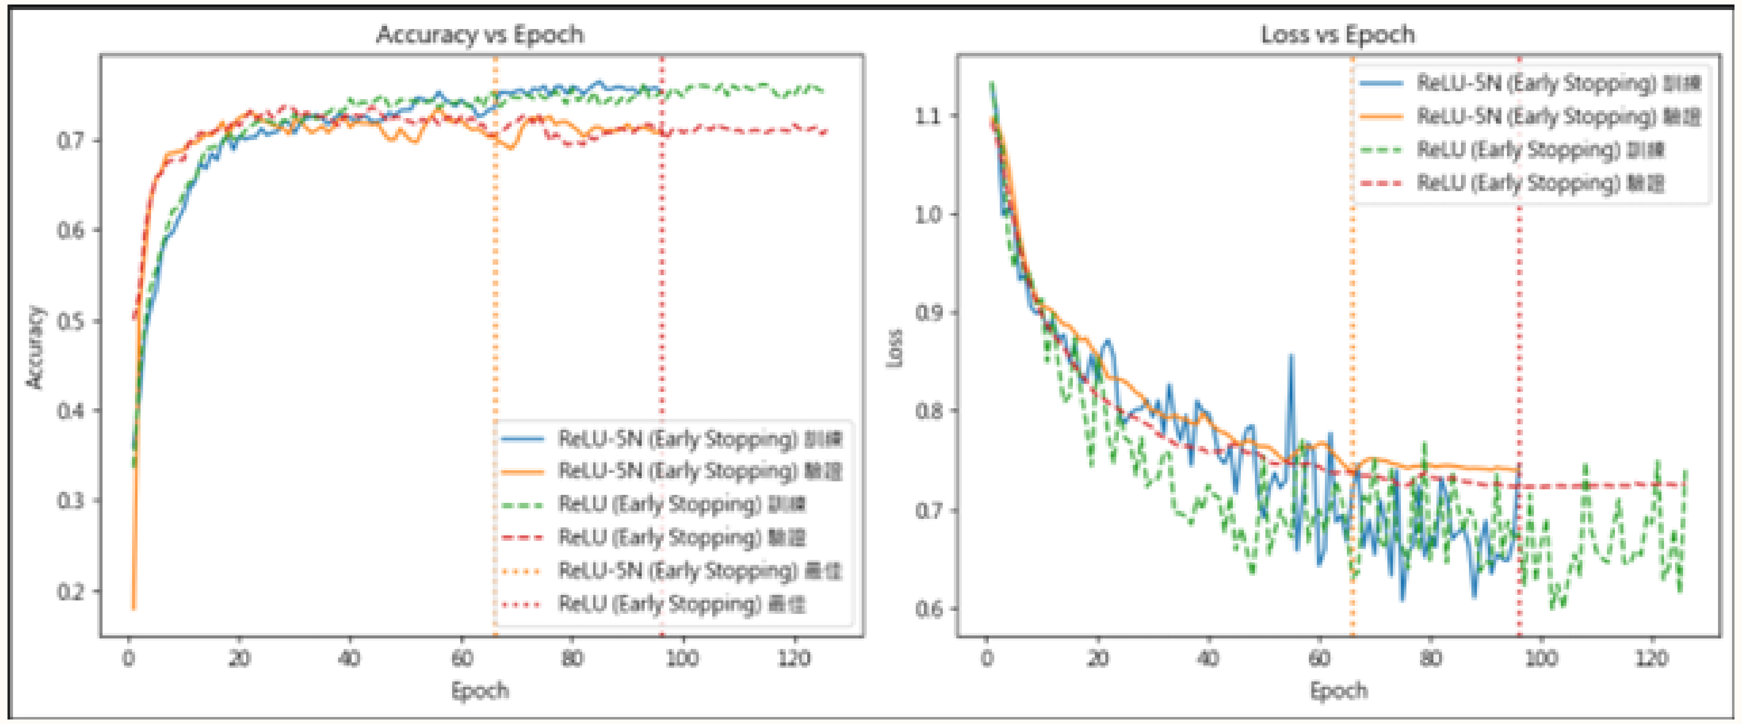


```
📊 === ReLU-5N (Early Stopping) 模型最終結果 ===
Train Loss: 0.7450
Val Loss:   0.7404
Train Acc:  0.7545
Val Acc:    0.7093

📊 === ReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.7418
Val Loss:   0.7268
Train Acc:  0.7526
Val Acc:    0.7108
```

測試

Batch size=256

2	MLP ReLU (ES)	0.748494	0.788433	0.748494	0.760966
3	MLP ReLU-5N (ES)	0.745482	0.797678	0.745482	0.761025

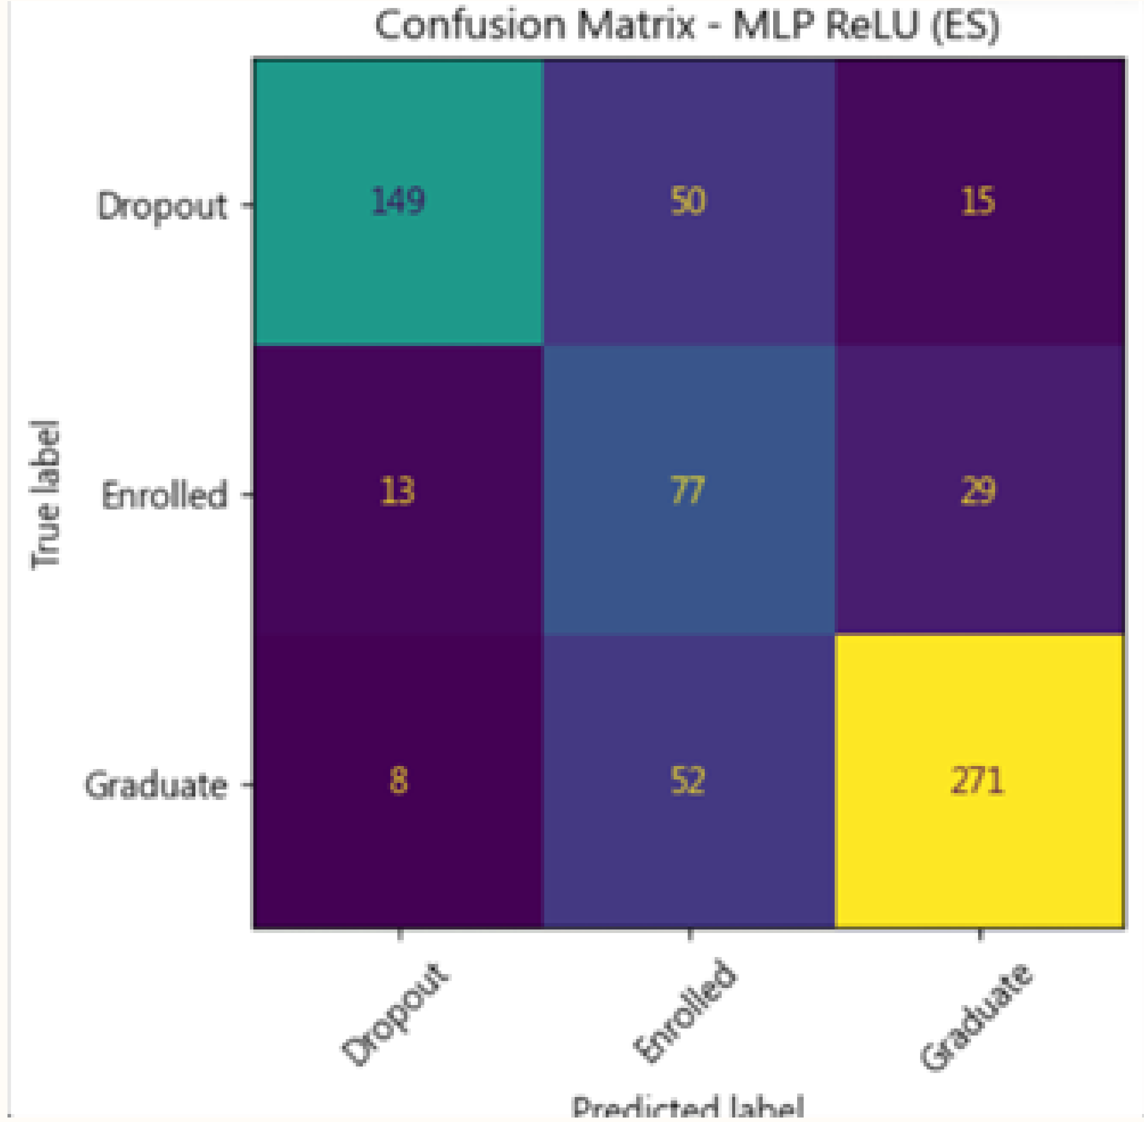

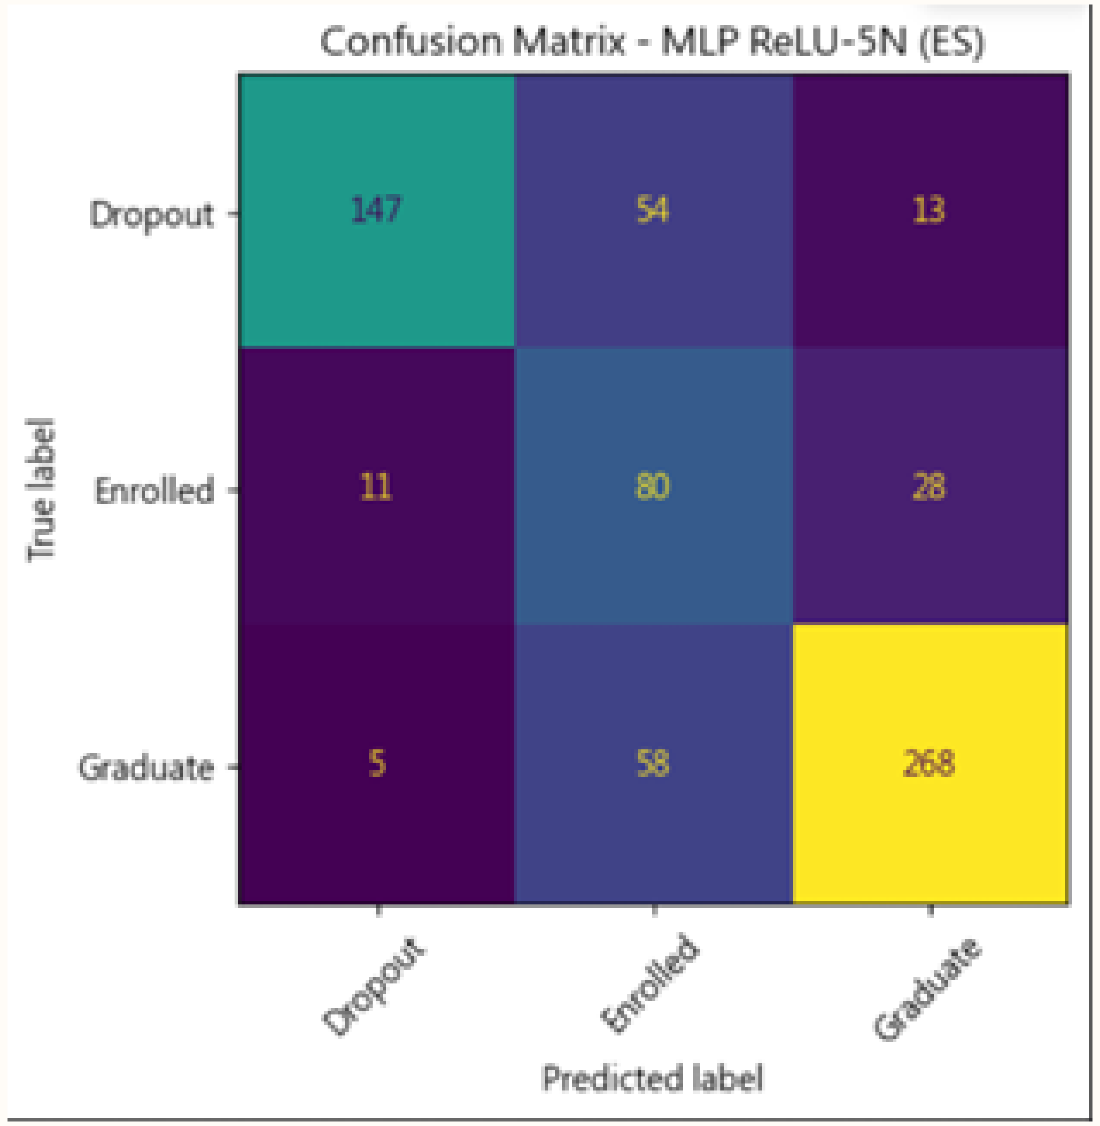

測試

Batch size=1024

2	MLP ReLU (ES)	0.763554	0.802031	0.763554	0.774270
3	MLP ReLU-5N (ES)	0.737952	0.807275	0.737952	0.756731

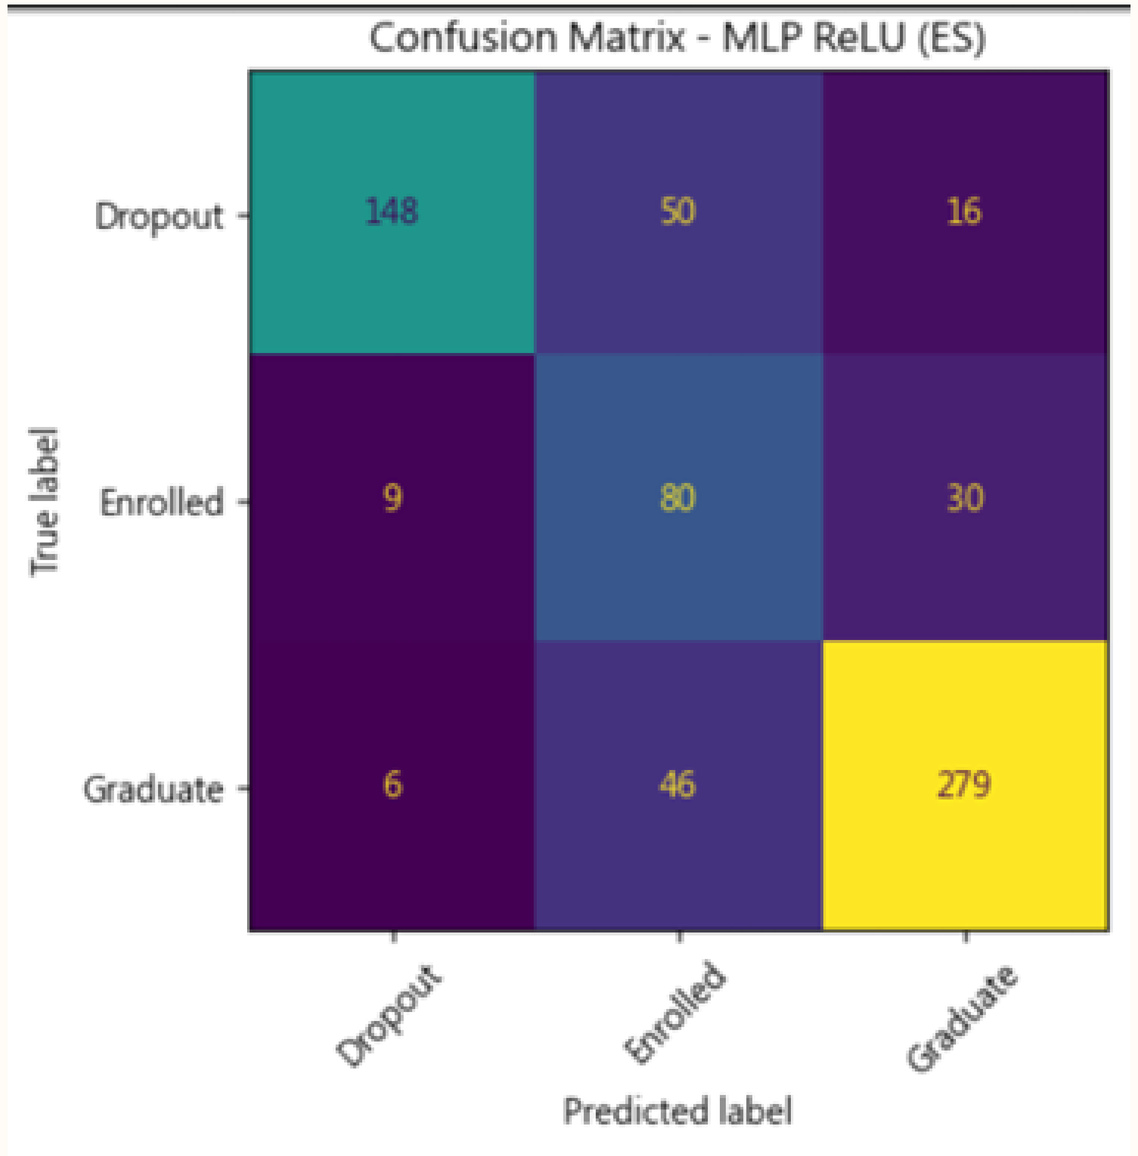

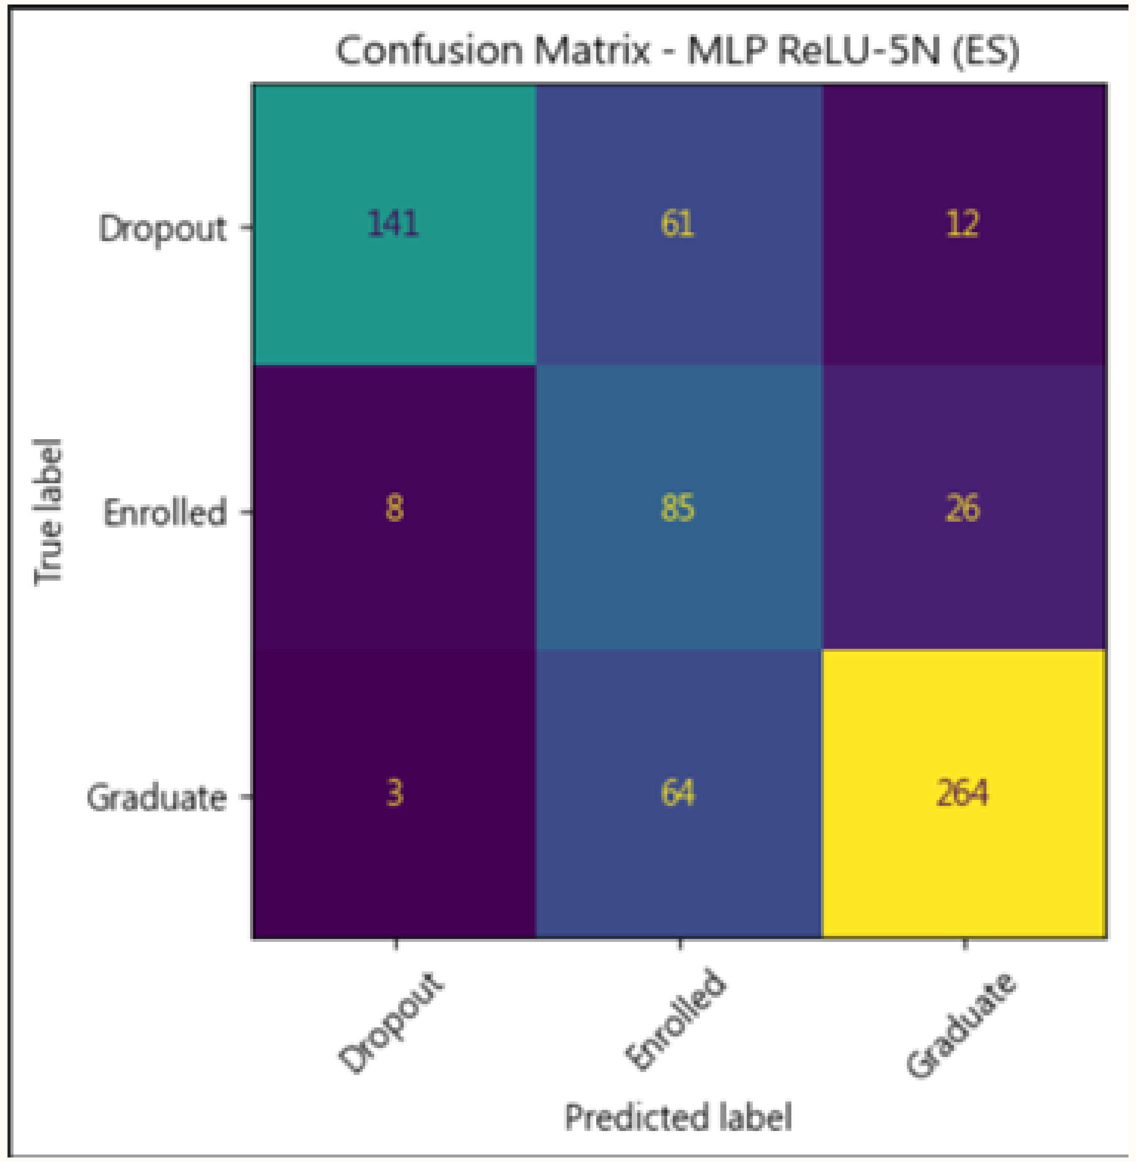

1. 初始學習率

IR=1e-3(0.001)

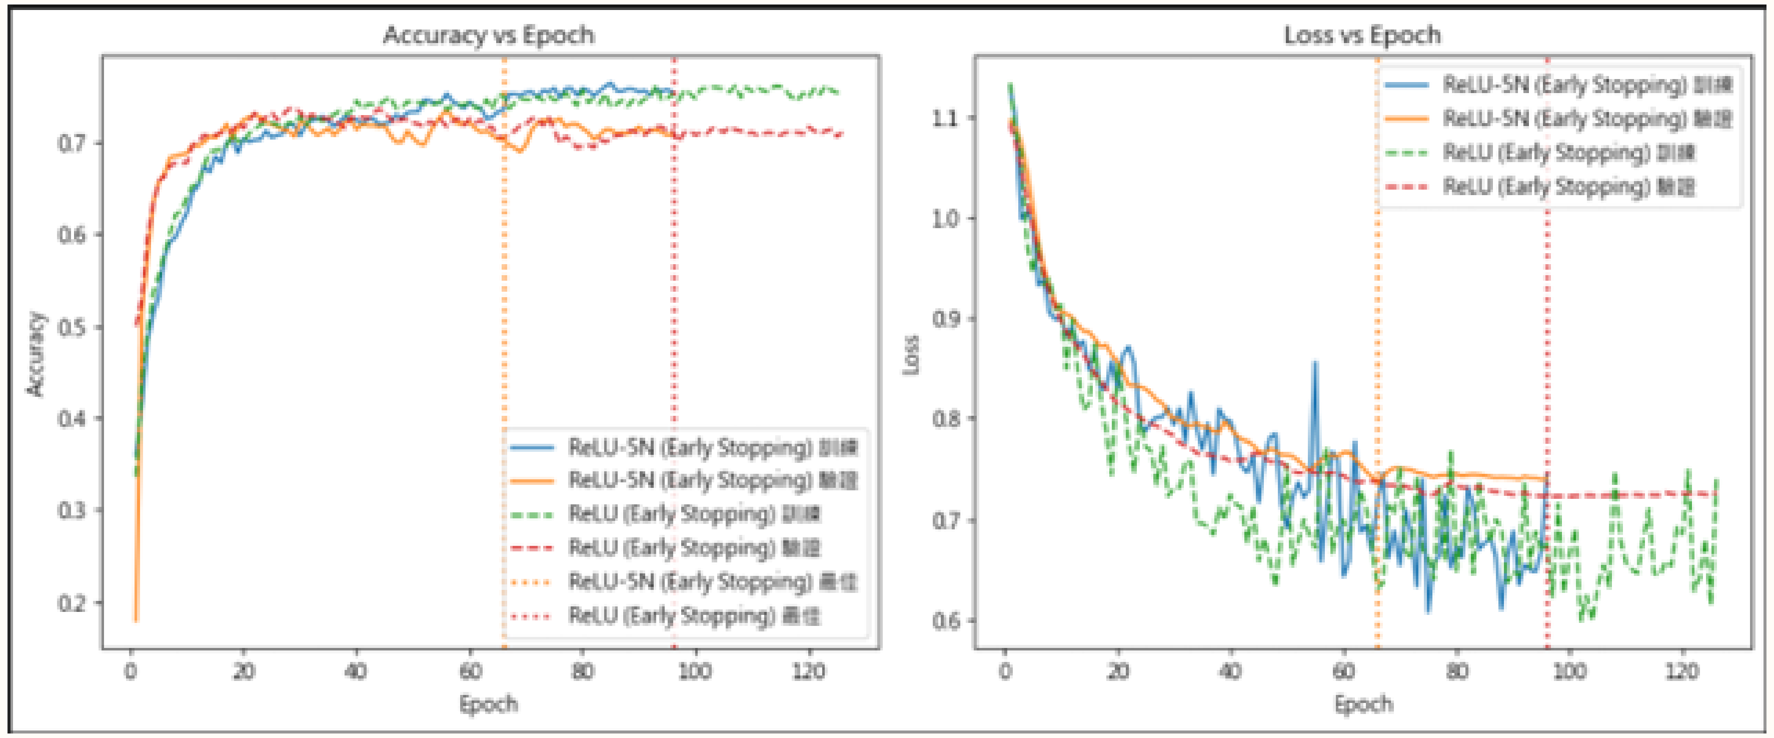


```
📊 === ReLU-5N (Early Stopping) 模型最終結果 ===
Train Loss: 0.7450
Val Loss:   0.7404
Train Acc:  0.7545
Val Acc:    0.7093

📊 === ReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.7418
Val Loss:   0.7268
Train Acc:  0.7526
Val Acc:    0.7108
```

IR=3e-4(0.0003)

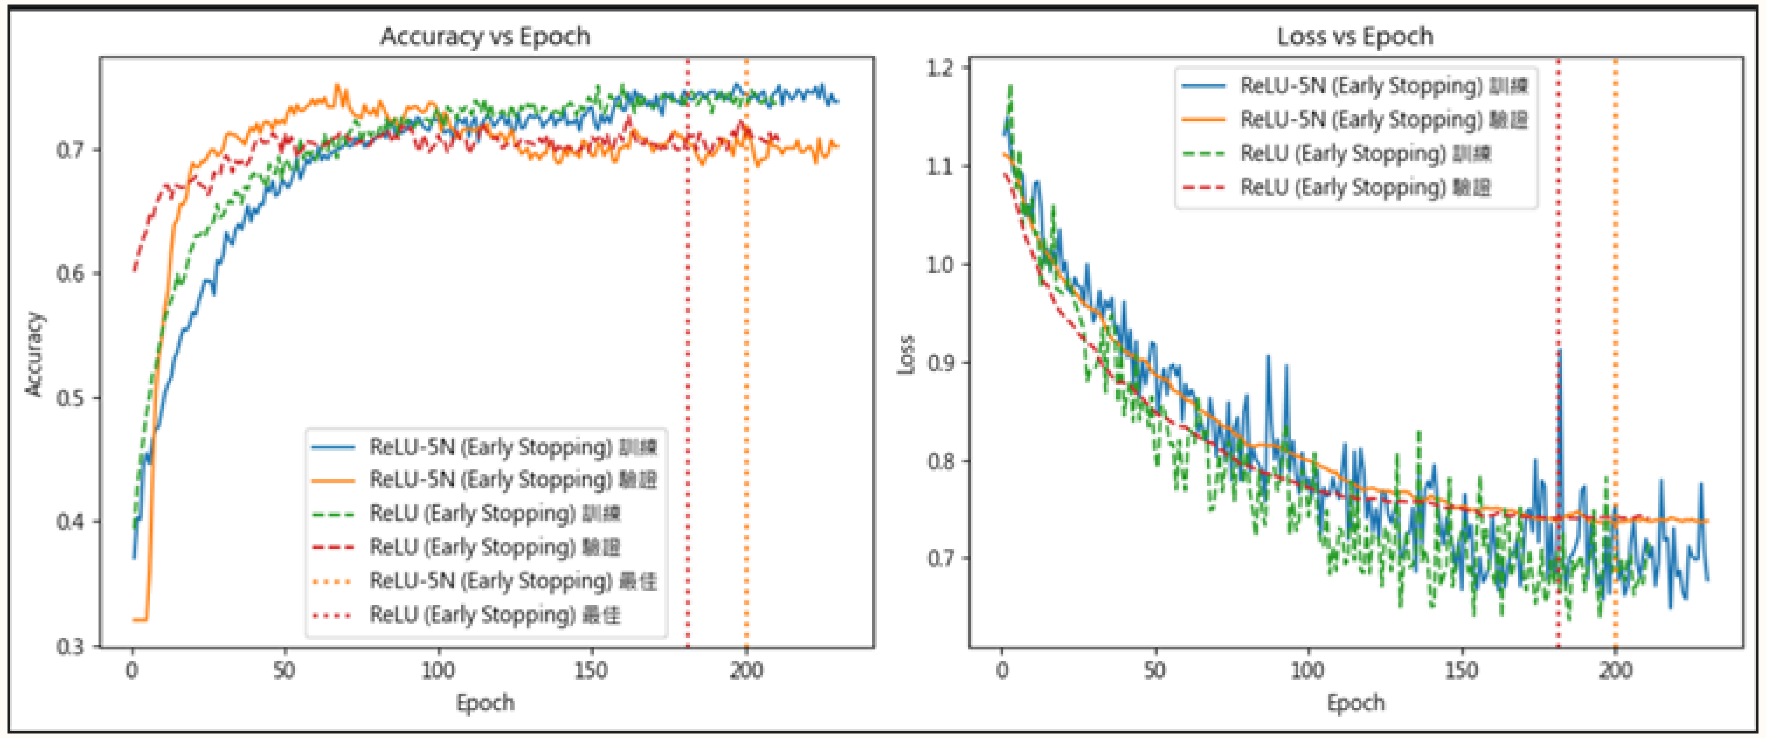


```
📊 === ReLU-5N (Early Stopping) 模型最終結果 ===
Train Loss: 0.6777
Val Loss:   0.7378
Train Acc:  0.7377
Val Acc:    0.7018

📊 === ReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.7161
Val Loss:   0.7406
Train Acc:  0.7364
Val Acc:    0.7048
```

測試

IR=1e-3(0.001)

2	MLP ReLU (ES)	0.763554	0.802031	0.763554	0.774270
3	MLP ReLU-5N (ES)	0.737952	0.807275	0.737952	0.756731

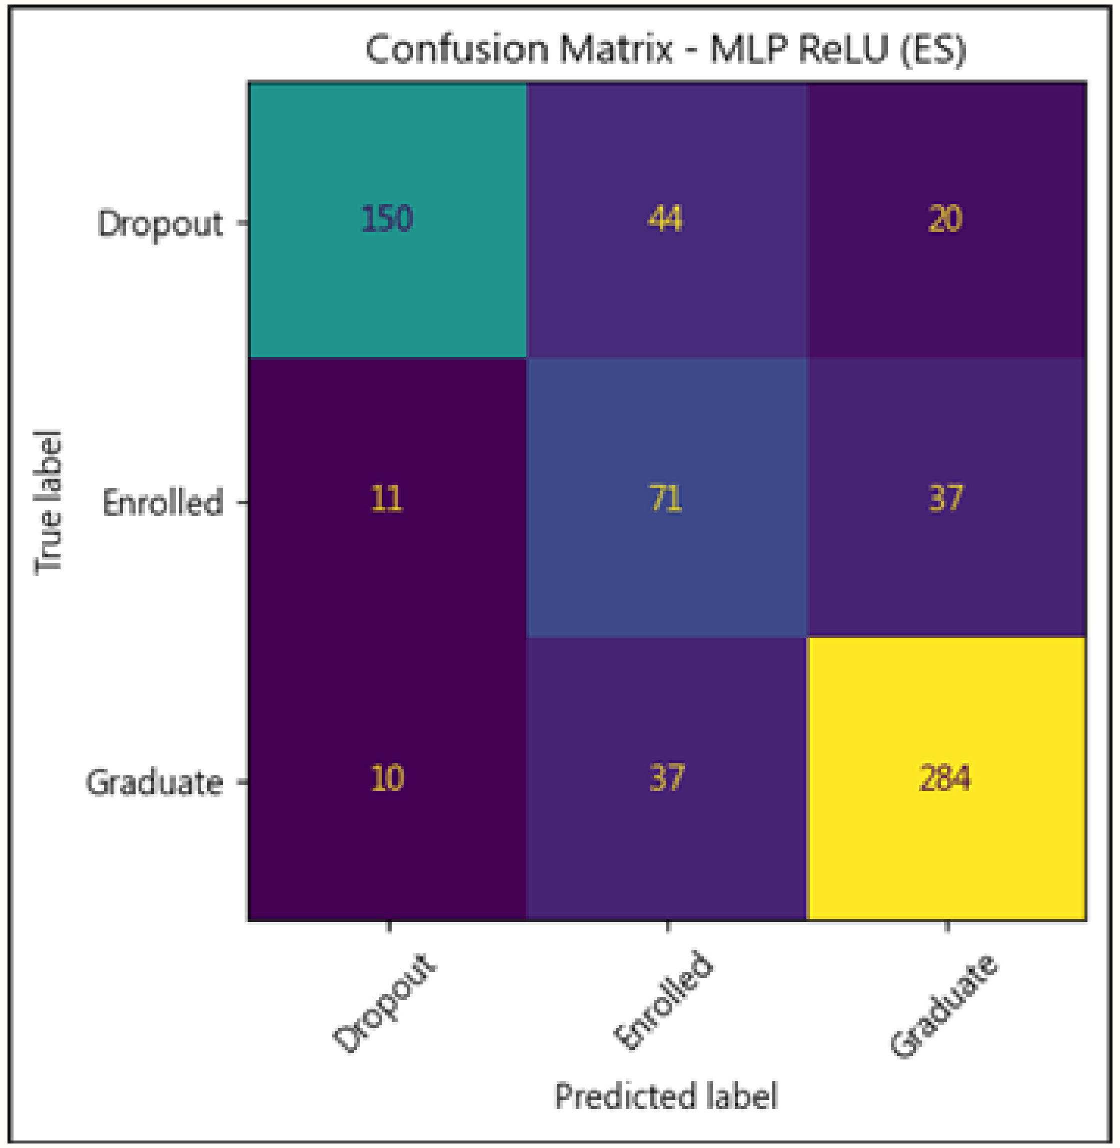

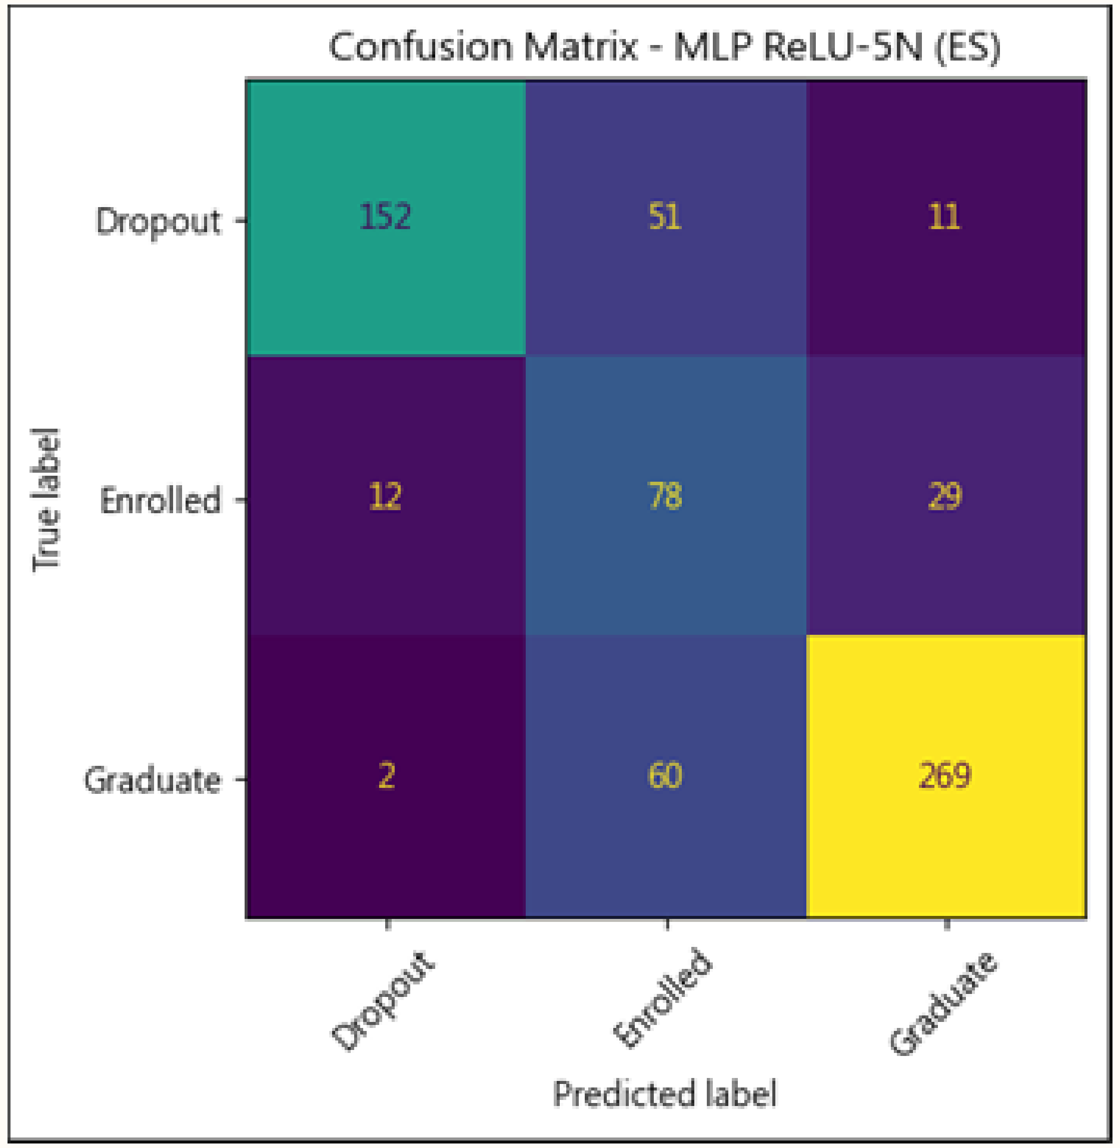

測試

IR=3e-4(0.0003)

2	MLP ReLU (ES)	0.759036	0.798841	0.759036	0.770170
3	MLP ReLU-5N (ES)	0.756024	0.804779	0.756024	0.769978

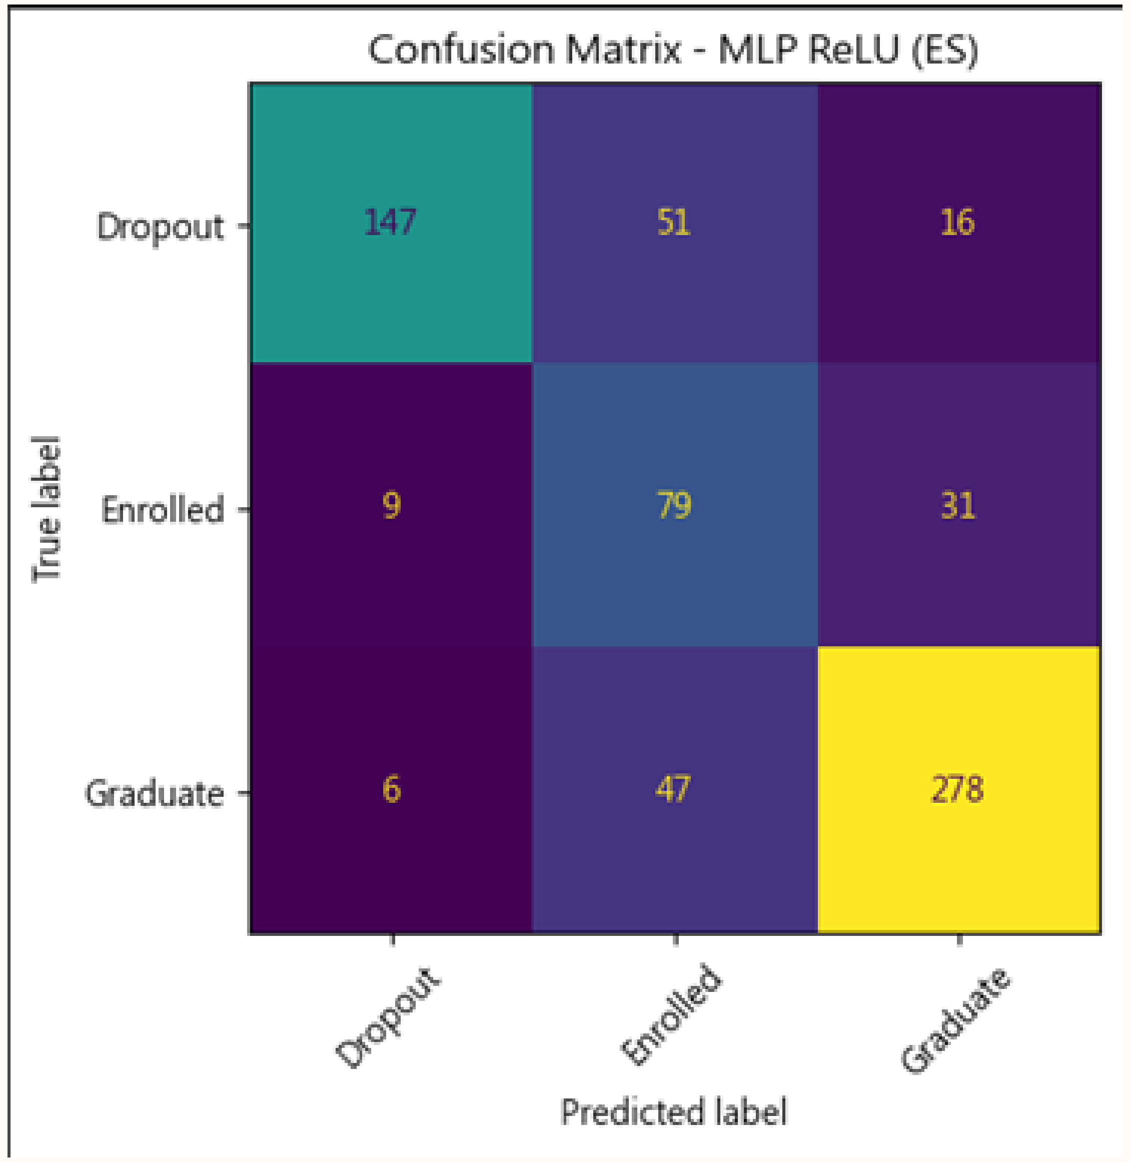

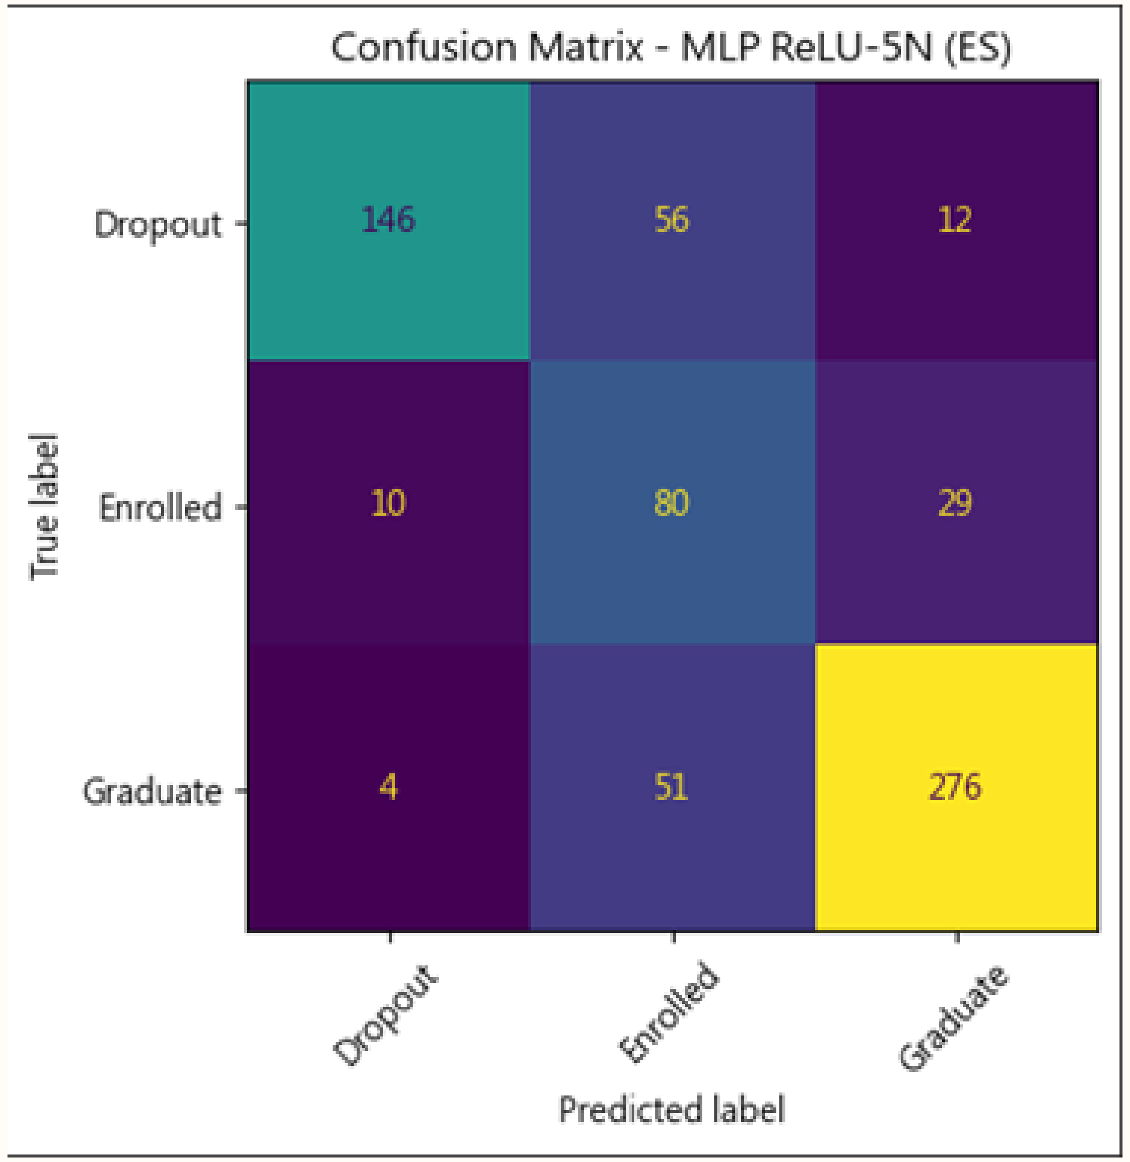

- 最佳參數組合
- 驗證、測試_batch_size=256
- 訓練batch_size =1024
- 優化器:Adam
- IR=1e-3
- weight_decay:L2正則
- 用驗證停止(30次無進步停止、最高300次)，

激活函數加上 Leaky_Relu(0.01) 比較 以及機器學習模型 XGboots 比

ReLU_2層 VS ReLU_5層

ReLU_2層 VS LeakyReLU

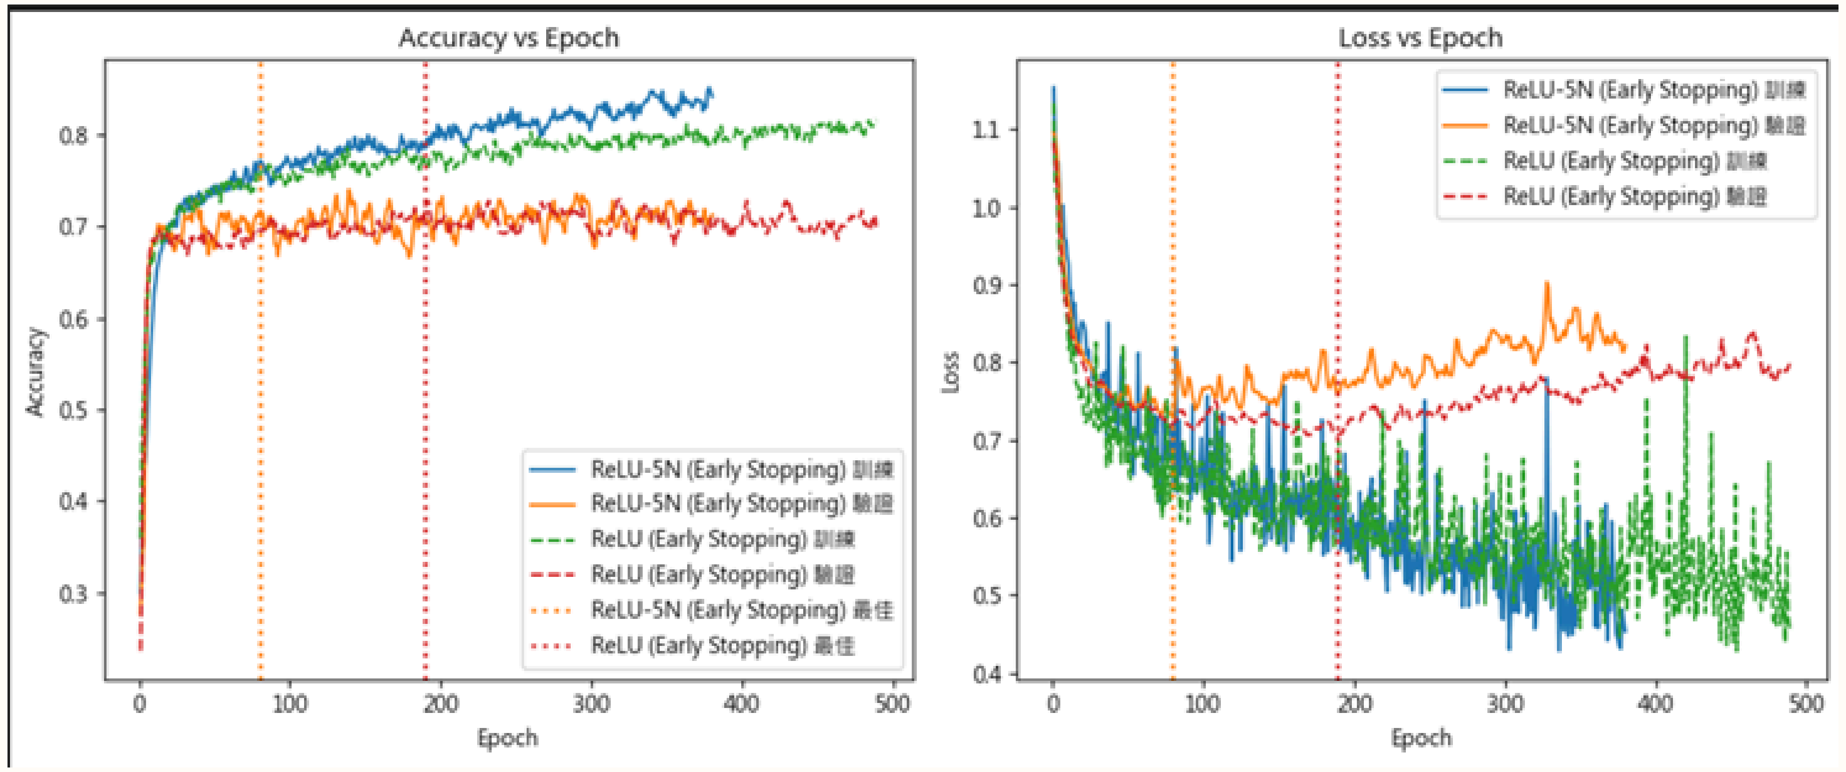

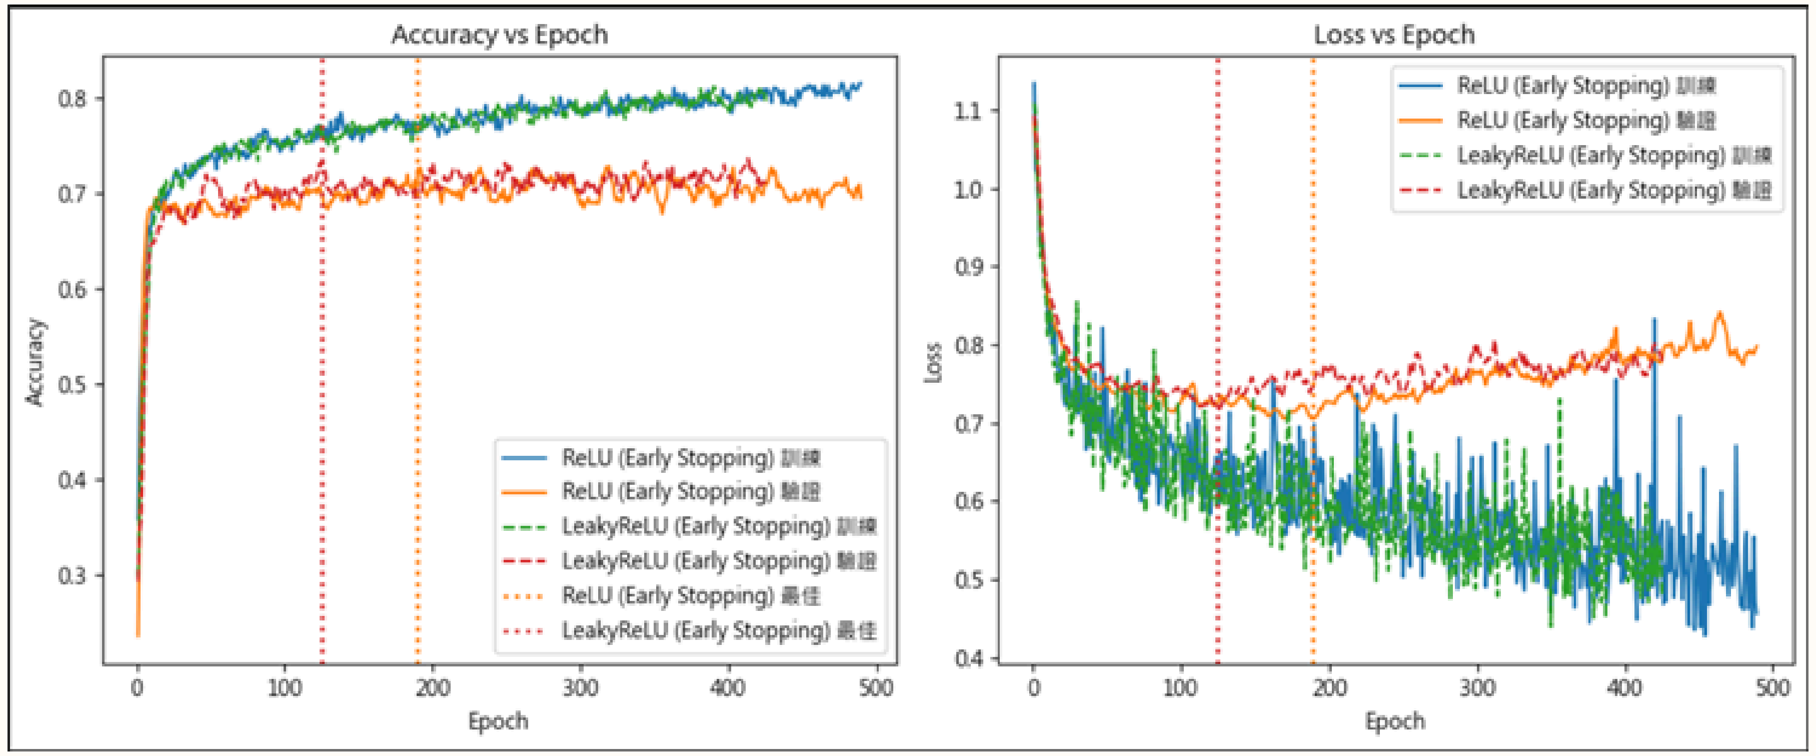


```
📊 === ReLU-5N (Early Stopping) 模型最終結果 ===
Train Loss: 0.7015
Val Loss:   0.7524
Train Acc:  0.7432
Val Acc:    0.7093

📊 === ReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.6755
Val Loss:   0.7515
Train Acc:  0.7384
Val Acc:    0.6988

📊 === LeakyReLU (Early Stopping) 模型最終結果 ===
Train Loss: 0.6773
Val Loss:   0.7506
Train Acc:  0.7183
Val Acc:    0.6807
```

測試

	Model	Accuracy	Precision(w)	Recall(w)	F1(w)
0	XGBoost	0.801205	0.795440	0.801205	0.795468
1	MLP LeakyReLU (ES)	0.768072	0.806118	0.768072	0.779533
2	MLP ReLU (ES)	0.733434	0.798545	0.733434	0.752466
3	MLP ReLU-5N (ES)	0.765060	0.804169	0.765060	0.775272

XGBoost

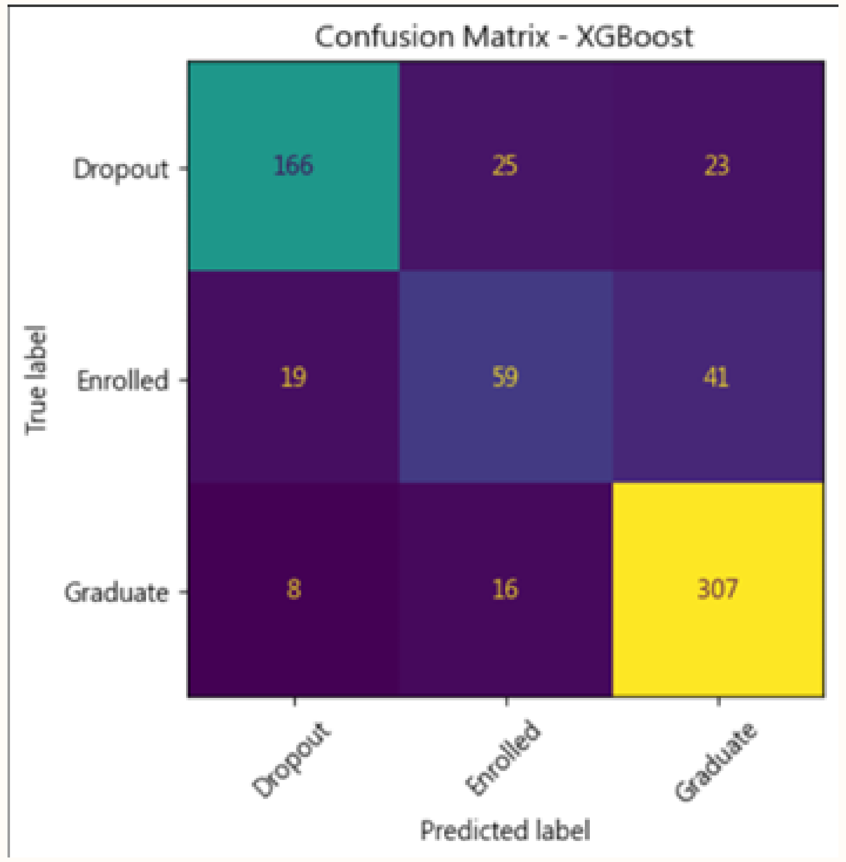

LeakyReLU

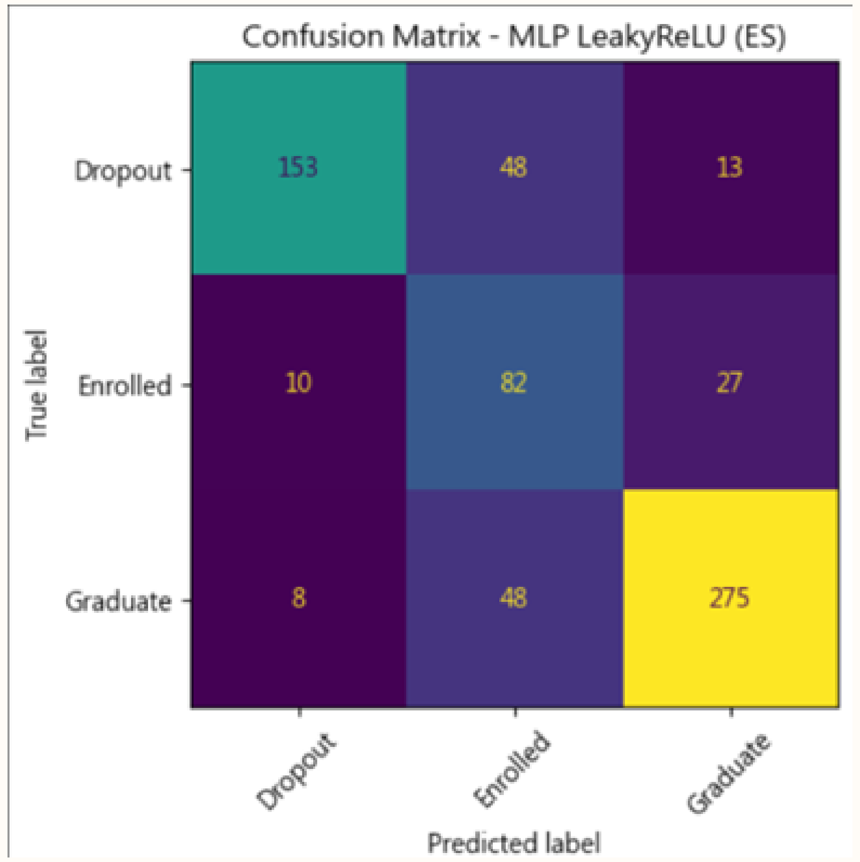

ReLU_2層

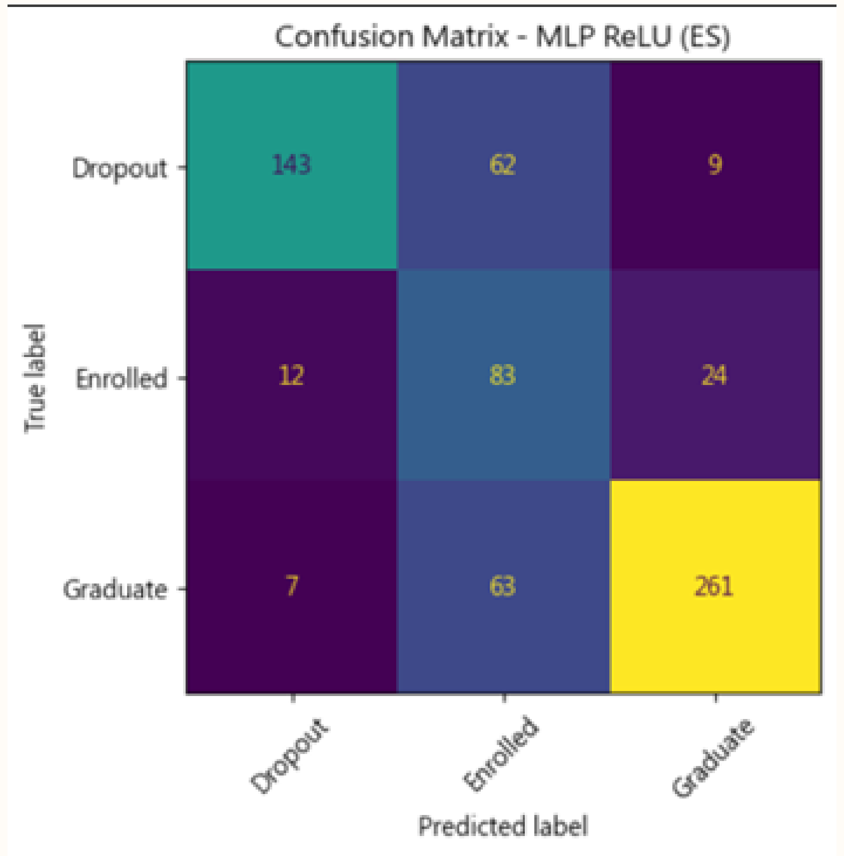

ReLU_5層

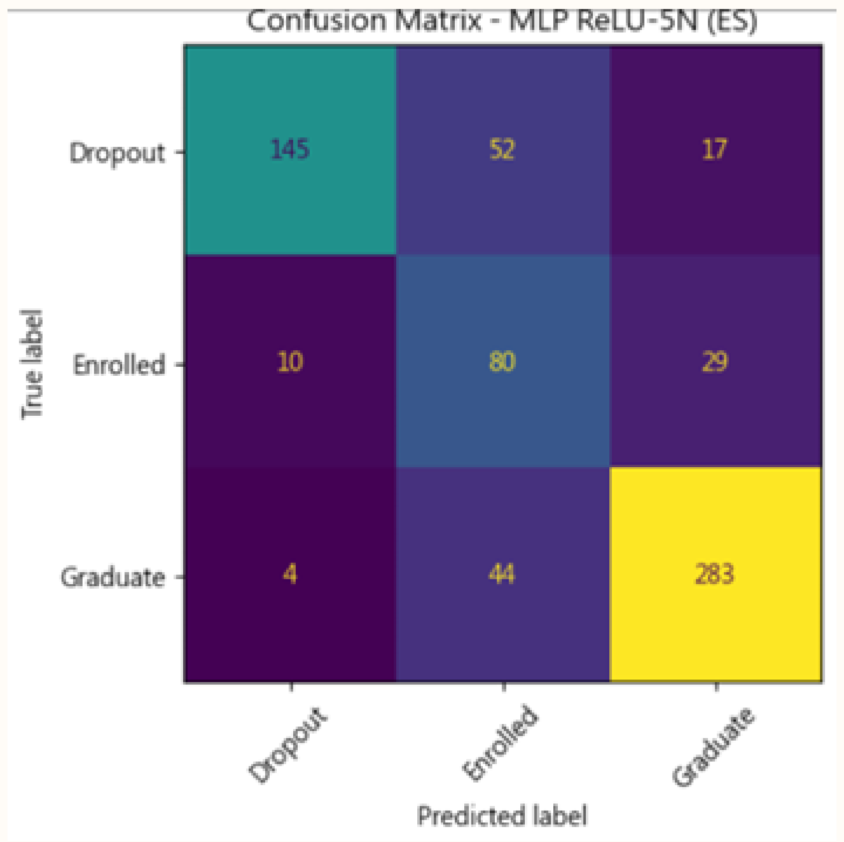

結論

- MLP 模型在不同超參數設定下（層數、Batch Size、學習率、激活函數）表現差異明顯。
- 兩層隱藏層（Relu_2N） 整體表現最佳，但在 Batch Size = 1024 時，Relu_5N 偶爾會更好，表示深層網路在大批次訓練下能學得更充分。
- 學習率 1e-3 表現最佳，收斂快又穩定；ReLU 激活函數效果也比 LeakyReLU 好。

謝謝大家